

RĪGAS TEHNISKĀ UNIVERSITĀTE

Datorzinātnes, informācijas tehnoloģijas un enerģētikas fakultāte

Informācijas tehnoloģijas institūts

Deniss Grabovskis

Akadēmisko bakalaura (pirmā cikla) studiju programmas

Informācijas tehnoloģija

students, stud. apl. nr. 231RDB217

**KOKMATERIĀLU PIEPRASĪJUMA
PROGNOZĒŠANA AR
MĀKSLĪGAJIEM NEIRONU
TĪKLIEM UN SINTĒTISKAJIEM
DATIEM
BAKALAURA DARBS**

Zinātniskais vadītājs Dr.sc.ing.

Henrihs Gorskis

RĪGA 2026

RĪGAS TEHNISKĀ UNIVERSITĀTE
DATORZINĀTNES, INFORMĀCIJAS TEHNOLOĢIJAS UN ENERĢĒTIKAS
FAKULTĀTE
Informācijas tehnoloģijas institūts

Bakalaura darba izpildes lapa

Noslēguma darba autors:

students Deniss Grabovskis _____

(paraksts, datums)

Noslēguma darbs ieteikts aizstāvēšanai:

Zinātniskais vadītājs:

Dr.sc.ing. Henrihs Gorskis _____

(paraksts, datums)

ANOTĀCIJA

KOKMATERIĀLU PIEPRASĪJUMA PROGNOZĒŠANA, PĀRDOŠANAS PROGNOZĒŠANA, LAIKA RINDA, LSTM, SINTĒTISKI DATI

Bakalaura darbs ir veltīts kokmateriālu pārdošanas pieprasījuma prognozēšanai, izmantojot reālus uzņēmuma datus. Precīzāka pieprasījuma prognozēšana var samazināt pārmērīgas krājumu uzkrāšanas un krājumu trūkuma risku. Sākotnēji uzņēmuma dati ir glabāti Excel failos, tāpēc darba gaitā tie tiek parsēti, normalizēti un pārveidoti strukturētā SQLite datubāzē. Strukturētie pārdošanas apjomi tika apkopoti pa materiālu grupām un izmantoti viena mēneša uz priekšu prognozēšanas modeļu apmācībai un salīdzināšanai. Tika salīdzinātas tradicionālās laika rindu metodes, kas ietver naivo metodi, vienkāršo eksponenciālo izlīdzināšanu un ARIMA, ar LSTM neironu tīklu. Naivā metode prognozēja tādos pārdošanas apjomus, kādi faktiski bija pēdējā mēnesī. LSTM modelis tiek apmācīts ar to pašu datu kopu kā citas metodes, bet tam papildus tika nodrošinātas aprēķinātas ar pārdošanu un piegādēm saistītas pazīmes. Eksperimentālie rezultāti parādīja, ka naivā metode sasniedza labāko kopējo WAPE rezultātu. Lai dziļāk novērtētu prognozes, tika izstrādāti divi pielāgoti rādītāji. LSTM modelis neuzrādīja labākus rezultātus nekā tradicionālās bāzes metodes, kas liecina, ka pašreizējais datu kopums ir pārāk īss, lai parādītu neironu tīkla pieejas priekšrocības, kuras parasti tiek sagaidītas šāda veida modeļiem. Bija arī novērtēta sintētiski papildinātu datu ietekme uz LSTM prognozēšanas spējām. Tā deva jauktus rezultātus, tāpēc tika veikta padziļināta analīze un secināts, ka tā palīdzēja tikai maza un nulles apjoma pārdošanas gadījumos.

Darba saturs – 58 lappuses, 7 attēli, 15 tabulas, 10 pielikumi, 41 izmantotais informācijas avots.

ABSTRACT

TIMBER DEMAND FORECASTING, SALES FORECASTING, TIME SERIES, LSTM, SYNTHETIC DATA

The bachelor's thesis is devoted to forecasting timber sales demand using real company data. More accurate demand forecasting can reduce the risk of overstocking and stock shortages. Initially, the company's data is stored in Excel files, so in the course of the work they are parsed, normalized and transformed into a structured SQLite database. The structured sales volumes were summarized by material groups and used to train and compare one-month-ahead forecasting models. Traditional time series methods, including the naive method, simple exponential smoothing and ARIMA, were compared with an LSTM neural network. The naive method predicted the same sales volumes as were recorded in the previous month. The LSTM model was trained on the same dataset as the other methods, but it was additionally provided with calculated features related to sales and deliveries. Experimental results showed that the naive method achieved the best overall WAPE result. To assess the forecasts in more detail, two custom metrics were developed. The LSTM model did not outperform the traditional baseline methods, suggesting that the current dataset is too short to demonstrate the advantages of the neural network approach that are typically expected for this type of model. The impact of synthetically augmented data on the forecasting performance of the LSTM model was also assessed. This gave mixed results, so a more in-depth analysis was performed, and it was concluded that augmentation was helpful only for low and zero-volume sales.

Thesis content – 58 pages, 7 images, 15 tables, 10 appendices, 41 information sources.

SATURA RĀDĪTĀJS

IEVADS	7
1. UZŅĒMUMA APRAKSTS UN SĀKOTNĒJIE DATI	9
2. LITERATŪRAS APRAKSTS	12
2.1. Uzņēmuma dati kā laika rindas un tradicionālās prognozēšanas metodes	12
2.2. Neironu tīkli laika rindām.....	14
2.3. Sintētiskie dati un ierobežota piemērojamība darba kontekstā	15
2.4. Kvalitātes rādītāji, modeļu salīdzināšanas sistēma un nākamie soļi	15
3. DATU PARSĒŠANA	17
4. DATU ANALĪZE	22
4.1. Prognozēšanas datu kopas īss apraksts	22
4.2. Datu laika pārklājums un novērojumu ierobežojumi	22
4.3. Pārdošana un piegādes kā analīzes objekti	24
4.4. Pārdošanas apjoma trūkums individuālā materiāla līmenī un apkopošanas līmeņa izvēle	25
4.5. Prognozētā mainīgā izvēle un rindu konstruēšanas noteikumi	27
4.6. Prognozēšanas problēmas galīgais izklāsts	28
5. PROGNOZĒŠANAS METOŽU REALIZĀCIJA UN SALĪDZINĀŠANA	30
5.1. Eksperimenta iestatīšana.....	30
5.2. Naivā prognoze.....	30
5.3. Vienkāršā eksponenciālā izlīdzināšana.....	31
5.4. ARIMA modelis	33
5.5. LSTM neironu tīkls	35
5.5.1. Neironu tīkls kā regresijas modelis	35
5.5.2. Aktivizācijas funkcijas	36
5.5.3. Tīkla apmācība.....	36
5.5.4. Optimizācija: SGD un adaptīvie optimizētāji	37
5.5.5. Pazīmju standartizācija un mērķa vērtības normalizācija	37
5.5.6. Rekurenti tīkli un LSTM atšķirība	39
5.5.7. Datu sagatavošana	39
5.5.8. Modeļa arhitektūra un apmācība	41
5.6. Procentuālās kļūdas ierobežojumi un papildu relatīvās kļūdas rādītāji	43
5.7. Metožu salīdzinājums un starpsecinājumi	45

6. DATU PAPILDINĀŠANA AR SINTĒTISKAJIEM DATIEM.....	48
6.1. Datu papildināšanas pieejas.....	48
6.2. Python implementācija.....	50
6.3. LSTM novērtēšana ar papildinātiem apmācības datiem.....	52
REZULTĀTI UN SECINĀJUMI.....	56
IZMANTOTIE INFORMĀCIJAS AVOTI	59
PIELIKUMI	64

IEVADS

Pieprasījuma prognozēšana ir uzņēmumu plānošanas rīks, kas ietekmē iepirkumu lēmumus. Prognozēšanas kļūdas var izraisīt pārmērīgu krājumu (noved pie papildu izmaksām) vai to deficītu (noved pie nokavētām pasūtījumiem un sliktāku klientu apkalpošanu). Abi scenāriji tik un tā noved pie naudu zaudējumiem (Bender, Bretschneider, & Fattah-Weil, 2024).

Literatūrā par pieprasījuma prognozēšanu ir aprakstītas dažādas pieejas. Piemēram, pastāv tradicionālās prognozēšanas metodes, kas balstās uz vēsturiskiem pārdošanas datiem. Problēma ir tā, ka pieprasījums var būt nelineārs un atkarīgs no citiem faktoriem (Bender, Bretschneider, & Fattah-Weil, 2024; Emerson & Napoleao, 2022). Šādas sakarības savukārt potenciāli var modelēt neironu tīklu modelis (Bender, Bretschneider, & Fattah-Weil, 2024; Eglite & Birzniece, 2022). Tomēr to izmantošana negarantē precīzāku rezultātu, tas ir atkarīgs no datu kopas, pieejamā apjoma un struktūras. Lai konstatētu uzlabojumu metodes ir jāsalīdzina savā starpā.

Neskatoties uz to, ka literatūrā ir daudz pētīti vairākas prognozēšanas metodes, ieviešanai nepieciešama datu un sistēmu sagatavotība. Pētījumos tiek uzsvērts, ka ir nepieciešams pareizi sagatavot datus pirms var ieviest mašīnmācīšanās prognozēšanas metodes (Aichner & Santa, 2023). Turklāt, neskatoties uz mašīnmācīšanās modeļu pieejamību, praksē joprojām tiek izmantotas tradicionālās statistiskās metodes un cilvēka pieredze (Aichner & Santa, 2023). Tāpēc šajā darbā tiek pārbaudīts kā alternatīva prognozēšanas pieeja – neironu tīkli – ir izmantojama reāla pieejamā kokapstrādes uzņēmumā un vai tā sniedz praktisku ieguvumu salīdzinājumā ar tradicionālām metodēm.

Tomēr šim uzņēmumam pastāv problēma – pieejamo vēsturisko datu apjoms ir ierobežots. Datu trūkums var ietekmēt prognozēšanas metožu precizitāti (Bender, Bretschneider, & Fattah-Weil, 2024; Emerson & Napoleao, 2022). Datus var papildināt ar sintētiskiem datiem pirms modeļa apmācības, tomēr rezultāts var atšķirties: dažos gadījumos tā var uzlabot prognozes precizitāti, dažos – pasliktināt (Semenoglou, Spiliotis, & Assimakopoulos, 2023; Wen, u.c., 2021). Līdz ar to šajā darbā tiks arī pētītas sintētisko datu papildināšanas metodes.

Ņemot vērā minēto, darbā tiek izvirzīti šādi pētījuma jautājumi.

1. Vai neironu tīkla modelis nodrošina precīzāku mēneša pārdošanas prognozi nekā tradicionālās laukrindu prognozēšanas metodes?

2. Vai sintētiski papildināti apmācības dati uzlabo neironu tīkla modeļa prognozēšanas precizitāti?

Darba mērķis ir sagatavot reāla kokapstrādes uzņēmuma pārdošanas datus prognozēšanai, pielietot un salīdzināt tradicionālās laicrindu prognozēšanas metodes ar neironu tīkla modeli, kā arī novērtēt sintētisko datu papildināšanas ietekmi uz prognožu precizitāti.

Lai sasniegtu darba mērķi, tika izvirzīti šādi uzdevumi:

1. analizēt uzņēmuma sniegtos datus;
2. izpētīt prognozēšanas metodes, kas ir piemērotas izvēlētajam datu tipam;
3. izpētīt neironu tīklu izmantošanu laicrindu prognozēšanā;
4. izpētīt sintētisko datu papildināšanas iespējas;
5. izstrādāt datu parsēšanas risinājumu, kas pārveido uzņēmuma Excel failus strukturētā datubāzē;
6. sagatavot uzņēmuma datus prognozēšanas modeļu apmācībai;
7. pielietot izvēlētas tradicionālās laicrindu prognozēšanas metodes;
8. pielietot neironu tīkla modeli;
9. sintētiski papildināt apmācības datus un pārbaudīt to ietekmi uz neironu tīkla modeļa rezultātiem;
10. salīdzināt iegūtos prognozēšanas rezultātus un izdarīt secinājumus.

Darba pirmajā nodaļā ir aprakstīts uzņēmums un sākotnējie dati. Otrajā nodaļā ir literatūras apskats par laicrindu datiem, tradicionālām prognozēšanas metodēm, neironu tīkliem, sintētiskajiem datiem un prognožu novērtēšanas rādītājiem. Trešajā nodaļā ir aprakstīta datu parsēšana un uzņēmuma Excel failu pārveidošana strukturētā formā. Tad praktiskajās nodaļās tiek analizēta sagatavotā datu kopa, pielietotas tradicionālās prognozēšanas metodes un neironu tīkla modelis, kā arī pārbaudīta sintētiski papildinātu datu ietekme uz prognozēšanas rezultātiem. Darba beigās ir apkopoti rezultāti un secinājumi. Pielikumos ir iekļauti papildu materiāli, kas saistīti ar datu apstrādi, modeļu realizāciju un prognozēšanas rezultātiem.

1. UZŅĒMUMA APRAKSTS UN SĀKOTNĒJIE DATI

Pētījums balstās uz datiem no reāla uzņēmuma. Uzņēmums apstrādā koksni un pārdod dažādus materiālus, sākot no maziem dēļiem un sagatavēm līdz gatavām koka konstrukcijām. Uzņēmums nodarbojas arī ar neliela apjoma kokmateriālu piegādi.

Lai īstenotu šo pētījumu, uzņēmums autoram sniedza reālus pārdošanas un piegāžu datus vairāku Excel izklājlapu veidā. Izklājlapas ietver simtiem atsevišķu rindu. Strādājot ar šiem datiem, autoram ir radījies jautājums par to pietiekamību stabilām prognozēm. Neskatoties uz pieņemama ierakstu skaita pieejamību, to garums un tajās ietvertā informācija var būt ierobežota. Tas ir viens no iemesliem, lai izpētītu datu sintēzes pieejas.

Uzņēmuma sniegtie dati satur informāciju par pārdošanas un piegāžu apjomiem atsevišķos laika periodos. Šajā darbā prognozēšanas mērķis ir pārdošanas apjoms, jo tas labāk raksturo pieprasījumu. Piegāžu datu piemērotība būs saprotama turpmākajā datu analīzē.

Neapstrādātie dati glabājās vairākos Excel failos, vairākās izklājlapās. Katrs fails atbilst vienam pārdošanas gadam, un gandrīz katra lapa šajā failā atbilst atsevišķam mēnesim. "Gandrīz katra", jo uzņēmums nolēma ierakstīt dažus metadatus pāris atsevišķās lapās. Lai gan dati šajos divu veidu lapās ir vizuāli atšķirīgi, tos ir vieglāk atšķirt pēc materiālu lapu nosaukumu formāta – *mm.yyyy*.

Katram materiālam tiek piešķirta viena datu rinda lapā. Lai gan tas ir ērti uzņēmuma darbiniekiem, no datu un datubāzes normalizācijas viedokļa tā ir nepareiza pieeja, jo tā pārkāpj vairākus datu glabāšanas noteikumus:

- materiāla īpašības (izmēri, zīmols, kvalitāte) tiek atkārtotas no lapas uz lapu: ja īpašība mainās vienā vietā, tā ir jāmaina desmitiem citu;
- lai gan tas nodrošina atsevišķu materiālu cenu un atlaižu vēsturi, vienam materiālam viena mēneša laikā nevar būt vairāk par vienu izmaiņu;
- kolonnu skalaritāte netiek saglabāta: pārdošanas un piegāžu apjomi konkrētajā mēnesī tiek reģistrēti vienā šūnā. Datubāzē šo problēmu varētu atrisināt, izveidojot atsevišķas pārdošanas un iepirkumu tabulas ar saitēm uz materiāliem;
- iepriekšējā mēneša atlikušā materiāla apjoma atkārtošana, lai gan darbiniekiem ir ērti, atkal pārkāpj unikalitātes noteikumu.

Visas šīs problēmas tiek atrisinātas datu parsēšanas posmā. Pilna informācija par tipisko izklājlapu, kurā ir ierakstīti materiālu dati, ir sniegta 1.1. tabulā.

1.1. tabula


Materiālu datu apraksts

Excel kolonnas nosaukums		Glabātās vērtības apraksts
Galvenes, kas neatrodas tieši augšējā rindā	Pirmā, bez nosaukuma, vertikāli apvienotā uz vairākām rindām	Zīmola nosaukums. Pastāv vairāki – Kartex, Buvnieks, Rondi.
	Pirmā rinda zem visām galvenēm, uz brūna fona	Kategorijas nosaukums. Zem šī rindas aprakstītie materiāli ir iekļauti šī kategorijā
KVALITĀTE		Kokmateriāla kvalitāte vai nosaukums
Ar izmēriem saistītās kolonnās	BIEZUMS (m) vai AUGSTUMS (m)	Metriskā vērtība, kolonnas nosaukums tika pamainīts ar laiku
	PLATUMS (m)	Metriskā vērtība
	GARUMS (m)	Metriskā vērtība
	m3 (1 gb)	Metriskā vērtība, sareizināts biežums, platums un garums
	m2 (1 gb)	Metriskā vērtība, sareizināts platums un garums
Ar cenu saistītās kolonnās	Iepirkuma cena	EUR
	Cena m3	EUR, iepirkuma cena reizināta ar materiālam individuāli piešķirto konstantu.
	Cena 1 gb	EUR, iepirkuma cena reizināta ar materiālam individuāli piešķirto citu konstantu, reizināta ar 1.21 un ar 'm3 (1gb)' kolonu
	Cena m2	EUR, cena par vienu gabali izdalītā ar platuma un garuma reizinājumu
Ar daudzumu saistītās kolonnas	DAUDZUMS (gb.)	No atlikuma gabalos atņemts pārdots gabalos, piešķirts saņemts gabalos
	Kopā m3	Daudzums gabalos rēķināts ar 'm3 (1gb)' kolonu
	Kopā m2	Daudzums gabalos rēķināts ar 'm2 (1gb)' kolonu
Ar pieprasījumu saistītās kolonnas	PĀRDOTS (gb.)	Skaitlis vai formula, kas saskaita vairākās pārdošanas (=1+2+3+...)
	PĀRDOTS (m3)	Pārdots gabalos reizināts ar kolonu 'm3 (1 gb)'
	PĀRDOTS (€)	Skaitlis vai formulas, kas saskaita vairāku pārdošanas saņemto naudu (=10+20+30+...)
Ar iepirkumu saistītās kolonnas	SAŅEMAM (gb.)	Skaitlis vai formula, kas saskaita vairākās saņemšanas (=1+2+3+...)
	SAŅEMAM (m3)	Saņemto materiālu skaits reizināta ar 'm3 (1gb)' kolonu
Ar atlikumu saistītās kolonnas	ATLIKUMS (gb.) vai IEPRIEKŠĒJAIS ATLIKUMS (gb.)	Iepriekšējā mēneša 'DAUDZUMS (gb.)' kolonnas vērtība. Ar laiku tika pārsauktā
	ATLIKUMS (m3)	Atlikums gabalos reizināts ar 'm3 (1 gb)' kolonu. Ar laiku tika noņemta

Excel kolonnas nosaukums		Glabātās vērtības apraksts
	ATLIKUMS (m2)	Atlikums gabalos reizināts ar 'm2 (1 gb)' kolonu. Ar laiku tika noņemta
	ATLIKUMS (€)	Atlikums gabalos reizināts ar 'Cena m3' kolonu

Reālo datu piemēru Excel failā var ieraudzīt 1. pielikumā.

Ir svarīgi atzīmēt, ka dati ir ierobežoti laikā: dokumentēti tikai aptuveni deviņu mēnešu pārdošanas apjomi: no 2025. gada jūlija līdz 2026. gada martam. Tas var tieši ietekmēt prognozes precizitāti, jo nav pieejams pilnīgs gada cikls, lai pilnībā ņemtu vērā sezonālos modeļus. Turklāt, neskatoties uz to, ka reģistrēšana sākās 2025. gada jūlijā, materiālu saraksts rakstīšanas laikā turpina paplašināties. 1.1. attēlā parādīts reģistrēto materiālu skaita pieaugums. Šis pieaugums ir saistīts nevis ar jaunu materiālu parādīšanos uzņēmumā, bet ar iepriekš neregistrētu materiālu pievienošanu kopīgajiem sarakstiem. Tas notika tādēļ, ka 2025. gada jūlijā tika uzsākts materiālu digitālās dokumentēšanas process, un uzņēmumam bija nepieciešami vairāki mēneši, lai iedokumentētu visus materiālus.



1.1. att. Dokumentēto materiālu daudzums

2. LITERATŪRAS APRAKSTS

Literatūras apskata galvenais mērķis ir noteikt, kādas metodes un neironu tīkls tiks izmantoti un salīdzināti. Lai to izdarītu, vispirms ir jāidentificē uzņēmuma datu tips, jo no tā ir atkarīga prognozēšanas metožu izvēle (Bender, Bretschneider, & Fattah-Weil, 2024). Pēc tam jāizvēlas metrikas rezultātu novērtēšanai. Šajā sadaļā ir aplūkotas arī datu papildināšanas metodes.

2.1. Uzņēmuma dati kā laika rindas un tradicionālās prognozēšanas metodes

Būtībā pieprasījuma prognozēšanas uzdevums ir paredzēt nākotnes pārdošanas apjomus: katram pārdošanas darījumam tiek piešķirts datums, un katru produktu tādējādi var kārtot pēc šiem pārdošanas apjomiem (piemēram, pārdošanas pa dienām/nedēļām/mēnešiem). Šī struktūra literatūrā parasti tiek uzskatīta par laika rindām (*time series*), kurai tiek izmantotas laika rindu prognozēšanas metodes (Ali & Nakti, 2023). Tas nozīmē, ka uzņēmuma sākotnējā Excel izklājlapa ir laika rindu kolekcija, un ka salīdzināšanai ir jāizvēlas laika rindu prognozēšanas modeļi un metodes, lai tie varētu prognozēt pārdošanas apjomus.

Literatūrā par pieprasījuma prognozēšanu ražošanas un piegādes ķēdēs tradicionālās metodes tiek raksturotas kā pieejas, kas izmanto vēsturiskos datus, identificē tendences un veido prognozes nākotnes periodiem. Šīs pieejas izšķir vienkāršus bāzes modeļus, slīdošos vidējos un ARIMA saimi (Bender, Bretschneider, & Fattah-Weil, 2024). Ir norādīts, ka vienkāršs slīdošais vidējais (*Simple Moving Average*) prognozē nākotni, aprēķinot pagātnes vidējo vērtību; svērtais slīdošais vidējais (*Weighted Moving Average*) prognozē nākotni, sverot pagātnes datu punktus; un ARIMA modelis integrē autoregresiju, diferenciāciju un slīdošo vidējo (*moving average*) vērtību (Bender, Bretschneider, & Fattah-Weil, 2024). Sezonālajām rindām pieprasījuma problēmās SARIMA/ARIMAX/SARIMAX ir īpaši minēti kā rīki sezonālītātes un/vai ārējo mainīgo ņemšanai vērā (Bender, Bretschneider, & Fattah-Weil, 2024).

Sašaurinot fokusu uz pārdošanas apjomiem, mazumtirdzniecības literatūrā tiek uzsvērts, ka laikrindu modeļi vēsturiski ir plaši izmantoti kopējo pārdošanas apjomu prognozēšanai, visbiežāk izmantojot vienkāršo eksponenciālo izlīdzināšanu (*Simple*

Exponential Smoothing) un tās paplašinājumus, kā arī ARIMA (Emerson & Napoleao, 2022). Lietišķajos salīdzinājumos pārdošanas apjomu prognozēšanai ar sezonālītāti tradicionālās metodes parasti arī ietver slīdošo vidējo, ARIMA un SARIMA, un pēc tam tās tiek salīdzinātas ar modernākiem modeļiem (Ali & Nakti, 2023). Mazumtirdzniecības prognozēšanas pārskatā arī norādīta eksponenciālā izlīdzināšana, laikrindu sadalīšana (*time series decomposition*), ARIMA un Holt-Winters metode kā tradicionālās izmantotās metodes (Suresh & Suresh, 2023).

SARIMA ir ARIMA paplašinājums sezonālām rindām: modelis pievieno ARIMA eksistējošam nesezonālam parametru kopumam $\{p, d, q\}$ un sezonālos $\{P, D, Q, s\}$. Parametrs p apzīmē autoregresijas kārtu, q raksturo slīdošā vidējā komponenti, d darbojas ar diferenciāciju, P, D un Q ir līdzīgi, bet strādā ar sezonālajām nobīdēm, un s apzīmē sezonas garumu, piemēram, 12 mēnešus gada sezonālībai (Sirisha, Belavagi, & Attigeri, 2022). Avotos SARIMA pielietojumu raksturo kā sarežģītu procesu: stacionaritātes pārbaude un nodrošināšana, ARIMA parametru pielāgošanā un novērtēšana un pēc tam prognozēšana (Pongdatu & Putra, 2018). Līdzīgos darbos SARIMA arī bieži tiek izmantota kā bāzes modelis sezonālu pārdošanas datu prognozēšanai. Pongdatu un Putra (2018) salīdzināja vairākas SARIMA konfigurācijas, izmantojot mazumtirdzniecības pārdošanas datus ar sezonāliem raksturlielumiem, un izvēlējās piemērotāko modeli pēc MAD kļūdas rādītāja. Savukārt tradicionālo un moderno prognozēšanas pieeju salīdzinājumā Ali un Nakti (2023) SARIMA īpaši rekomendē ātras aprites un sezonāliem pārdošanas datiem.

Bija minēts arī Holt-Winters metode, kas ir eksponenciālās izlīdzināšanas metožu saime, paplašina vienkāršu izlīdzināšanu un ņem vērā tendences un sezonālītāti. Tā ir aprakstīta kā metode, ko izmanto, ja dati uzrāda tendences un sezonālu uzvedību, un tā ir arī sadalīta multiplikatīvos un aditīvos sezonālītātes variantos (Pongdatu & Putra, 2018). Mazumtirdzniecības prognozēšanas pārskatā Holt-Winters metode parādās arī kā viena no standarta tradicionālajām metodēm līdzās ARIMA un eksponenciālajai izlīdzināšanai (Suresh & Suresh, 2023).

Ņemot vērā apskatīto literatūru, sākotnēji kā piemērotākie tradicionālie modeļi šim darbam ir uzskatāmi eksponenciālā izlīdzināšana un SARIMA, jo šīs pieejas bieži tiek izmantotas pārdošanas un sezonālu laikrindu prognozēšanas pētījumos. Būs jāapsver arī Holt-Winters metodi, lai gan tas nešķiet īpaši populārs, bet tā teorētiski var būt piemērota šim uzdevumam. Tomēr galīgais tradicionālo metožu kopums šajā darbā tiks noteikts pēc uzņēmuma datu analīzes.

2.2. Neironu tīkli laika rindām

Neironu tīklu izmantošana pārdošanas prognozēšanā ir novērotā vairākos avotos. Dziļās mācīšanās (DL) modeļi tiek uzskatīti par atsevišķu jomu, literatūrā ir uzskaitīti DL ietvari un novērtēšanas rādītāji, kā arī tiek apspriestas DL priekšrocības un ierobežojumi pārdošanas prognozēšanā (Eglite & Birzniece, 2022). Pārdošanas datu ar sezonālītāti salīdzinošajos pētījumos bieži tiek izmantots LSTM un tā varianti (Ali & Nakti, 2023). LSTM ir definēts kā RNN paplašinājums, kas risina RNN īstermiņa atmiņas problēmu (izzūdošie gradienti) un ļauj saglabāt atkarības ilgākā laika periodā, izmantojot šūnas stāvokli un vārtu mehānismu (Yunita, et al., 2025). Līdzīgu ilgtermiņa atkarību problēmu risināšanai tika piedāvātas arī transformatoru arhitektūras (modernie LLM), kuras izmanto uzmanības (*attention*) mehānismu, nevis rekurentās saites starp laika soļiem (Vaswani, et al., 2017).

Avotos par pieprasījuma prognozēšanu piegādes ķēdēs LSTM spēj labāk uztvert laika rindu nelineārās atkarības nekā dažas statistiskās un mašīnmācīšanās bāzes modeles, un tiek salīdzināts ar ETS (*Error, Trend, Seasonality*) eksponenciālās izlīdzināšanas modeļiem, ARIMA un RNN, izmantojot vēsturiskos pārdošanas datus (Filali, et al., 2022). Laika rindu neironu tīklu arhitektūru salīdzinājums parāda, ka galīgā "labākā" iespēja ir atkarīga no metrikas un datu kopas; bet hibrīdi, kuru pamatā ir LSTM/GRU, bieži vien šķiet spēcīgāki nekā "vienkāršas RNN", un atšķirības ne vienmēr ir statistiski nozīmīgas (Yunita, et al., 2025). Citiem vārdiem sakot, literatūrā nepastāv viennozīmīgi dominējoša rekurentā arhitektūra laika rindu prognozēšanā.

LSTM laika gaitā saglabā slēpto stāvokli un šūnas stāvokli (*cell state*); šī stāvokļa atjaunināšanu (*input/forget/output*) kontrolē vārti (*gates*). Tas samazina gradientu izzušanas problēmu un saglabā vairāk atbilstošu informāciju no pagātnes (Yunita, et al., 2025; Filali, et al., 2022). Modelis mācās no rindu iepriekšējo vērtību secībām un prognozē nākamo vērtību (vai to kopu), mēģinot uztvert nelineāras atkarības, kuras tradicionālās laikrindu metodes ne vienmēr spēj aprakstīt (Filali, et al., 2022).

Tā kā literatūrā LSTM modelis ir plaši izmantots laika rindu prognozēšanā un ir uzskatīts par piemērotu neironu tīklu pieeju pārdošanas datiem, šajā darbā tika nolemts koncentrēties tieši uz LSTM modeli, nevis paplašināt pētījumu ar vairāku rekurento neironu tīklu arhitektūru savstarpēju salīdzināšanu.

2.3. Sintētiskie dati un ierobežota piemērojamība darba kontekstā

Sintētisko laika rindu pētījumos sintētiskie dati tiek izmantoti kā veids, kā iegūt papildu novērojumus situācijās, kur reālo datu apjoms ir nepietiekams. Pulla, Yasarer un Yarbrough (2024) rakstā par “*Synthetic Wells*” mērķis ir ģenerēt sintētiskas gruntsūdens līmeņa laika rindas datu trūkuma apstākļos, izmantojot SDV ietvara PAR modeli un novērtējot sintētisko datu līdzību ar reālajiem datiem. Darbā tiek apskatīta arī cita sintētisko datu ģenerēšanas pieeja – GAN – kurai ir norādītas apmācības grūtības, procesa nestabilitāte un neobjektīvu datu ģenerēšanas risks. Savukārt laika domēna papildināšanā tiek uzsvērts traucējumu risks no trokšņa un neatbilstošiem mainīgajiem (Hu, Hu, Li, & Du, 2023). Tādēļ konkrētā sintētisko datu papildināšanas pieeja šajā darbā tiks pamatota vēlāk, datu papildināšanas ar sintētiskajiem datiem sadaļā, balstoties uz datu analīzē konstatētajiem ierobežojumiem. Abos pētījumos datu papildināšanu izmanto potenciālai prognozēšanas modeļu veikspējas uzlabošanai.

2.4. Kvalitātes rādītāji, modeļu salīdzināšanas sistēma un nākamie soļi

Eglītes un Bērziņas (2022) pētījumā par mazumtirdzniecības prognozēšanu modeļu kvalitātes novērtēšanai tiek izmantoti vairāki kļūdu rādītāji:

- MAE – vidējā absolūtā kļūda;
- MAPE – vidējā absolūtā procentuālā kļūda;
- RMSE – vidējā kvadrātiskā kļūda;
- wMAPE – svērtā vidējā absolūtā procentuālā kļūda.

Darbā ir norādīts, ka MAPE ir ērts relatīvās kļūdas salīdzināšanai procentos, savukārt RMSE vairāk pastiprina lielākas prognozēšanas kļūdas. WMAPE mazāk pastiprina mazu faktiskisko vērtību ietekmi uz kopējo kļūdu (Forbes, 2021). Ali un Nakti (2023) sava pētījumā izmanto RMSE, lai novērtēt pārdošanas modeļus ar sezonalitāti salīdzināšanu. Pongdatu un Putra (2018) ARIMA salīdzinājumā atsevišķi izmantoja MAD, un MSE minēja kā kopīgu rādītāju. Citā salīdzinošā pētījumā par RNN/LSTM/GRU arhitektūrām tiek arī izmantota MAE, MAPE un RMSE, un atsevišķi tiek apspriests, ka “labākais” rezultāts var atšķirties atkarībā no rādītāja un tā, kas tieši tiek uzskatīts par prioritāti (Yunita, et al., 2025). RMSE, MAPE un SMAPE

tiek izmantoti arī LSTM pieprasījuma prognozēšanai piegādes ķēdēs, kas pierāda, ka tie parasti ir pielietoti salīdzināšanai pieprasījuma problēmās (Filali, et al., 2022).

Līdz ar to šī darba beigu metriku kopums ir MAE, RMSE, MAPE un WAPE. SMAPE var izmantot kā alternatīvu procentuālajai kļūdai. MAD ir metrika SARIMA novērtēšanai (Pongdatu & Putra, 2018), līdz ar to tā lietošana vēl nav apstiprināta..

Šī darba ideja ir apmācīt/pielāgot modeļus (gan tradicionālus, gan neironu tīklu LSTM), izmantojot vienu un to pašu apmācības datu kopu, un salīdzināt to prognozes vienā un tajā pašā testa periodā. Šāda pieeja tiek izmantota arī minētajos laika rindu prognozēšanas pētījumos (Ali & Nakti, 2023; Sirisha, Belavagi, & Attigeri, 2022; Forbes, 2021).

Literatūras apskatā tika noteikts, ka uzņēmuma pārdošanas dati ir laika rindas, tāpēc to prognozēšanai ir jāizvēlas laika rindu prognozēšanas metodes. Kā sākotnēji piemērotākās tradicionālās pieejas tika identificēta eksponenciālā izlīdzināšana, SARIMA (vai ARIMA) un potenciāli Holt-Winters, savukārt no neironu tīklu pieejām šajā darbā tika izvēlēts LSTM modelis. Tika arī secināts, ka sintētisko datu izmantošana var būt noderīga ierobežota datu apjoma gadījumā, tomēr konkrētā papildināšanas pieeja ir jāvērtē pēc uzņēmuma datu analīzes. Modeļu salīdzināšanai tika noteikti MAE, RMSE, MAPE un WAPE rādītāji. Tāpēc nākamajā nodaļā ir jāizanalizē uzņēmuma dati, lai precizētu galīgo prognozēšanas uzdevumu un metodes.

3. DATU PARSĒŠANA

Pirms datu analīzes un modeļu apmācības, uzņēmuma dati bija jāpārveido datoriem saprotama veidā, kā arī autoram saprotama, strukturētā veidā. Līdz ar to Python palīgskripts tika izstrādāts uzņēmuma datu par materiāliem, pārdošanu un piegādēm sākotnējai apstrādei un normalizēšanai. *timber_parse.py* skripts īsteno *ETL* pieeju: tā mērķis ir paņemt neapstrādātus Excel failus no norādītas mapes, atrast lapas, kurās ir ikmēneša dati, no šīm lapām iegūt informāciju par materiāliem, krājumiem, pārdošanas apjomiem un piegādēm un pēc tam visu to konvertēt normalizētākā SQLite datubāzes struktūrā ar nosaukumu *timber.sqlite*, ko rada no jauna ar katru skriptu palaišanu.

1. *Extract* – izvelk datus no Excel.
2. *Transform* – attīra, normalizē, labo īpašus gadījumus un sadala apkopotus laukus atsevišķos ierakstos.
3. *Load* – ielādē rezultātu SQLite.

Normalizētie dati tika saglabāti SQLite datubāzē, nevis uzreiz nodoti prognozēšanas modeļiem vairāku iemeslu dēļ. Pirmkārt, šāda pieeja atviegloja datu analīzi, jo pārdošanas un piegāžu informāciju kļuva iespējams filtrēt, grupēt un salīdzināt starp dažādiem laika periodiem un materiālu grupām. Otrkārt, tā atvieglo modeļu apmācības, jo ar to dati tiek fiziski atdalītas, tas ļauj labāk redzēt kā un kādi dati tiek atkārtoti izmantoti apmācībā. Arī autoram bija vieglāk saprast un redzēt visas datu relācijas. Turklāt katram ierakstam tika saglabāta informācija par sākotnējo failu, lapu un rindu, kas atviegloja atklādošanu. Tieši SQLite tika izvēlēta autora iepriekšējās pieredzes un vienkāršās integrācijas ar Python dēļ.

log.py palīgmodulis ir izmantots buferētai skripta ziņojumu izvadei apstrādes laikā. Tas izmanto standarta izvadi, bet ievieš vienkāršu pielāgotu mehānismu. Tas satur funkcijas kā:

- *prefix()* - konteksta pārvaldnieks - īslaicīgi iestāda kopīgu prefiksu visiem izvadītiem ziņojumiem drukāšanu;
- *log()* - drukā ziņojumus;
- *enable()* – iespējot visu moduli;
- *throttle()* – iespējot buferi, kas sāks izvadīt ziņojumus pēc daļām, lai konsole netiktu pastāvīgi pārblīvota.

Apstrāde sākas, meklējot Excel failus avotu direktorijā. Katram failam darbgrāmata tiek ielādēta divas reizes un no šī brīža šis pāris tiks uzskatīts par vienu darbgrāmatu. Pirmā darbgrāmata palīdz nolasīt aprēķinātās šūnu vērtības, un otrā - nolasītu formulas. Diemžēl Python bibliotēka, ko izmanto Excel failu lasīšanai (*openpyxl*), nevar atbalstīt gan aprēķinātās vērtības, gan formulas atsevišķu lasīšanu, izmantojot vienu atvērtu darbgrāmatas instanci. Tāpēc tika ieviests šāds risinājums, jo skriptam bija vienlaikus jāpaļaujas gan uz šūnas gala vērtību, gan uz formulu, ja ir nepieciešams rekonstruēt vairākus atsevišķus pārdošanas vai piegādes darījumus no vienas šūnas. Piemēram, ja Excel šūnā atrodas formula $=1+2+3$, pārdošanas kolonā tas reprezentē trīs atsevišķas pārdošanas darījumus ar apjomu 1, 2 un 3 vienības. Tādējādi skripts nav ierobežots ar galīgo vērtību 6, bet var rekonstruēt trīs atsevišķus darījumus.

Skripts ar *read_periods()* atlasa tikai tās lapas, kuru nosaukumi atbilst *mm.yyyy* formātam, tās lapas attēlo atsevišķus mēneša periodus. Tas atdala lapas, kas satur mēneša datus, no citām lapām, kas satur metadatus. Katrai atbilstošajai lapai funkcija atgriež struktūru, kas satur pašu lapu, tās formulu pāri un parsēto mēnesi un gadu.

Pēc tam ar *worksheet_records()* no katras lapas tiek iegūtas materiālu rindas. Tas ļauj veikt gan vērtību attīrīšanu, gan ierakstu analīzi.

1. Pirmajās 10 rindās tā meklē galvenes rindu ar tekstu, izmantojot “KVALITĀTE” galvenes kā atsauci.
 - a. Ja galvenes netiek atrastas, funkcija vienkārši pārtrauc darbu.
2. Pēc tam tā sāk lapas rindu pa rindai pārskatīšanu.
 - a. Ja tiek atrasta KOPĀ VISS, visa lapa ir beigusies.
 - b. Zīmolu nosaka pirmās kolonnas šūnas, kas ir apvienoti uz vairākām rindām – katrā rinda satur atsevišķa materiāla informāciju.
 - c. Kategorija tiek atcerēta no otrās kolonnas un aizmirstā, kad kāda no iterācijām rindā ir atrasts “KOPĀ” teksts, kas nozīme, ka šī zīmola materiālu saraksts ir beigusies.
3. Tukšas rindas tiek izlaistas.
4. Katrai rindai tiek izveidota ierakstu vārdnīca. Katrā ieraksta reprezentācijā pastāv četri atribūti:
 - a. *text* – normalizētais šūnas teksts;
 - b. *formula* – formula bez ‘=’ zīmes;
 - c. *float* – skaitliskā reprezentācija;
 - d. *_text_cell* – atsauce uz sākotnējo šūnu.

Šis koda fragments konstruē ierakstus, ko var izmantot sākotnējo tekstu un iepriekš aprēķinātu skaitli nolasīšanai, kā arī, ja nepieciešams, sadalīt apkopotās vērtības no formulas. Šī funkcija ir lapas centrālais "parsētājs". Tā pārveido neapstrādātu Excel tabulas struktūru standartizētā iekšējā Python struktūrā.

Īpašu gadījumu apstrāde arī ir svarīga ieviešanas daļa, kas novērš potenciālās kļūdas. Uzņēmuma dati satur daļēji kļūdainus ierakstus, tāpēc kodā ir ierakstīts (*hardcoded*) noteikumu kopums to labošanai. Tas ir realizēts ar *handle_special_cases()* funkcijas palīdzību – tieši tā glabā noteikumus. Tai ir divi darbības režīmi:

1. tiek nodots iepriekš formatēts ieraksts, un funkcija izlabo problemātiskos laukus:
 - a. aizstāj tekstu "Daniil" pirkuma cenas laukā ar 0. Šī vērtība uzņēmuma datus tika izmantota kā iekšējs apzīmējums, kas nav tieši izmantojams skaitliskajā analīzē. Kamēr darbiniekiem tas ir ērta pieeja, datu pārsēšanai un turpmākai analīzei tas traucētu, ja tā nebūtu aizstāvēta ar skaitlisko vērtību;
 - b. aizstāj biežumu no augstuma un otrādi, ja trūkst kāda no dimensijām. Kā bija minēts datu aprakstā, dažādas kolonnas tika pārsauktas ar laiku. Šī ir viena no tiem;
 - c. atlikušā daudzuma kolonna arī tika pārsaukta, šis gadījums arī bija atsevišķi apstrādāts transformācijas posmā;
 - d. ar laiku kolonnas, kas glabāja atlikušo daudzumu m3 vai m2 tika noņemtas;
2. kad kategorijas jau ir nodotas atsevišķi. Šajā gadījumā funkcija normalizē zīmolus un kategorijas:
 - a. BUVNIEKS gadījumā tā izlabo kategorijas "Zāģmateriāli" un "Ēvelēts/Ēvelēti" nosaukums;
 - b. KARTEX WOOD saīsināti tiek saukts par KARTEX;
 - c. RONDĪ gadījumā tas izlabo kategoriju "no Zviedrijas" uz C24.

Īpašu gadījumu apstrāde ir pielāgota šim konkrētam uzņēmumam datu kopas faktiskajām problēmām, tas nav universāls Excel parseris. To var ieraudzīt koda: tīrīšana pamatojas uz zināmām problēmām, kas atrastas uzņēmuma Excel failos.

Apstrādes rezultāts tiek sadalīts četrās tabulās SQLite datubāzē.

Materiālu tabulā tiek glabāts pats materiāla objekts: zīmols, kategorija, kvalitāte, izmēri un rindas izcelsmes metadati. Katrs materiāls saņem ID ar

material_hash() funkcijas palīdzību, kas atgriež materiāla SHA256 jaucēj kodu (*hash*), pamatojoties uz tā zīmolu, kategoriju, kvalitāti un mērījumu kombināciju. Tas nozīmē, ka identiskiem materiāliem, kas atrodami dažādās lapās, būs viens un tas pats ID. Šī pieeja samazina dublēšanos un palīdz pārveidot modeli "viena Excel rinda = viens objekts" par normalizētu modeli "materiāls + saistītie stāvokļi".

Tabulā *end_of_month_material_stats* tiek glabāts materiāla statusa momentuzņēmums mēneša beigās. Tajā ir ietvertas pārdošanas un piegāžu dati dažādās mērvienībās, kā arī atlikumi gabalos, kubikmetros, kvadrātmetros un eiro.

sales tabulā tiek glabāti pārdošanas apjomi. Katrs ieraksts ir saistīts ar materiālu, gadu un mēnesi. Ka bija minēts iepriekš, pārdošanas ir reģistrētas, izmantojot formulu, piemēram, $=1+2+3$, kur katrs skaitlis apzīmē pārdošanas darījumu šim materiālā šomēnes. Nolasot to, skripts ģenerē trīs atsevišķus *sales* tabulas ierakstus, saistot to ar vienu materiālu. *deliveries* tabula ir strukturēta līdzīgi, bet attiecas uz materiālu saņemšanu. Formulas interpretēšanas ir realizēta ar *parse_sales()* un *parse_deliveries()* funkcijām, respektīvi.

Visās tabulās ir kolonas *file_name*, *sheet_name*, *sheet_name_orderable* un *row*., kas noderīgi atklādošanai un izsekošanai: jebkuru ierakstu datubāzē var izmantot, lai noteiktu failu, lapu un rindu, no kuras tas nācis.

Galīgā ielāde datubāzē tiek veikta partijās. Pēc katras lapas apstrādes uzkrātie ieraksti tiek ievietoti SQLite, novēršot ID konfliktus. Tas novērš materiālu dublēšanos un saglabā galīgās datu struktūras konsekveni.

Pilns izstrādātā risinājuma pirmkods ir pieejams GitHub repozitorijā (denissgrabovskis/bachelor, 2026). Iegūto datubāzes struktūru var redzēt 3.1. attēlā.

Tables (4)		Tables (4)	
deliveries		deliveries	
id	BLOB	end_of_month_material_stats	
material_id	TEXT	materials	
year	INTEGER	id	TEXT
month	INTEGER	brand	TEXT
received_pcs	REAL	category	TEXT
received_m3	REAL	quality	TEXT
file_name	TEXT	height_m	REAL
sheet_name	TEXT	width_m	REAL
sheet_name_orderable	TEXT	length_m	REAL
row	INTEGER	file_name	TEXT
end_of_month_material_stats		sheet_name	TEXT
id	BLOB	sheet_name_orderable	TEXT
material_id	TEXT	row	INTEGER
year	INTEGER	sales	
month	INTEGER	id	BLOB
price_purchase	REAL	material_id	TEXT
price_m3	REAL	year	INTEGER
price_pcs	REAL	month	INTEGER
price_m2	REAL	sale_pcs	REAL
qty_pcs	REAL	sale_m3	REAL
qty_m3	REAL	sale_eur	REAL
qty_m2	REAL	file_name	TEXT
qty_eur	REAL	sheet_name	TEXT
file_name	TEXT	sheet_name_orderable	TEXT
sheet_name	TEXT	row	INTEGER
sheet_name_orderable	TEXT		
row	INTEGER		

3.1. att. SQLite datubāzes struktūra

4. DATU ANALĪZE

4.1. Prognozēšanas datu kopas īss apraksts

Prognozēšanas uzdevumā pārdošanas tabula ir svarīgāka, jo tā ir pamats mērķa mainīgā (kas saistīts ar pārdošanas apjomu) turpmākai veidošanai. Piegāžu tabulai ir papildu nozīme – piegādes var izmantot kā papildu ievades pazīmes neironu tīkla pieejā. Zemāk ir parādīts īss datubāzes apraksts.

4.1. tabula

Datubāzes apraksts

Datu bāzes tabula	Apraksts	Ierakstu skaits	Izmantošana prognozēšanā
<i>materials</i>	Materiālu direktorijs: zīmols, kategorija, izmēri, kvalitāte	206	Izmanto agregēšanai (zīmols+kategorija)
<i>sales</i>	Pārdošanas ieraksti pa materiāliem un mēnešiem	502	Mērķa mainīgā primārais avots (<i>sale_m3</i>)
<i>deliveries</i>	Materiālu piegādes ieraksti	46	Izmanto kā palīgpažīmes (tikai priekš neironu tīklām)
<i>end_of_month_material_stats</i>	Materiālu statistika mēneša beigās (cenas, atlikumi utt.)	1417	Izmanto papildu datu analīzei


Tādējādi šajā posmā sākotnējie dati jau ir pārveidoti analītiski piemērotā formā, un nākamais uzdevums ir novērtēt, cik lielā mērā šie dati ir piemēroti prognozējošo modeļu konstruēšanai.

4.2. Datu laika pārklājums un novērojumu ierobežojumi

Iepriekš bija minēts, ka pieejamie novērojumi aptver periodu no 2025. gada jūlija līdz 2026. gada martam (ieskaitot). Tas nozīmē, ka ir pieejami tikai deviņu secīgu mēnešu novērojumi. Tas vien jau rada būtiskus ierobežojumus turpmākajai prognozēšanai, jo datus trūkst pat viena pilnīga gada cikla. Līdz ar to, pat ja datiem piemīt sezonālitate, to ir grūti pilnībā noteikt un pārbaudīt tik īsa laika periodā.

Papildu sarežģījums ir tas, ka novērojumi ir ne tikai īsi, bet arī bija veidoti pakāpeniski – pirmajos mēnešos dokumentēto materiālu saraksts turpināja paplašināties, kas nozīmē, ka daži produkti nebija ievadīti sistēmā ar pirmo mēnesī. Tas

bija apspriests uzņēmuma apraksta nodaļā, bet ar datubāzi tas bija pilnība pierādīts. Tāpēc agrīnās vērtības sērijā atspoguļo ne tikai faktiskos pārdošanas apjomus, bet arī pašas grāmatvedības pilnīgumu. Tas nozīmē, ka zemāki pārdošanas apjomi sākumā (pirmajos mēnešos) ne vienmēr norāda uz tikpat zemu faktisko pieprasījumu. To vizuāli var ieraudzīt 4.1. attēlā.



4.1. att. Pārdošanas apjoms un dokumentēto materiālu skaits pa mēnešiem

Pirmajos četros mēnešos korelācija starp dokumentēto materiālu skaitu un kopējo pārdošanas apjomu ir 0,99.


No grafika var nolasīt divas lietas. Pirmais, pirmajos mēnešos dokumentēto materiālu skaits vēl palielinājās, kas nozīmē, ka agrīnie periodi jāvērtē piesardzīgi. Korelācija starp pārdošanas apjomiem mēnesī un dokumentētu materiālu skaitu pirmajos četros mēnešos ir skaidri redzama; to apstiprina arī aprēķinātā korelācija 0,99. Ir arī vērts atzīmēt, ka dokumentēto materiālu skaits turpmākajos nedaudz mēnešos samazinājās: tas var būt saistīts ar dažādiem procesiem uzņēmumā, un teorētiski tam nevajadzētu ietekmēt prognozi, taču ir vērts to paturēt prātā. Otrais, ir redzams, ka novērotais periods ir īss, jo laika ass attēlo tikai daļu no viena pilna gada. Tas nozīmē, ka prognozei vajadzētu mazāk paļauties uz sezonalitāti, nekā sākotnēji bija domāts.

Tas noved pie svarīga starpsecinājuma: pieejamie dati ir ierobežoti gan laika horizonta ilguma, gan agrīno novērojumu pilnīguma ziņā. Vēlāk tas kļūst par vienu no galvenajiem iemesliem, kāpēc tika nolemts izmantot plašāku prognozēšanas mērķi – materiālu grupu apkopotos pārdošanas apjomus, nevis atsevišķu materiālu pārdošanas

apjomus. Tas arī nozīmē, ka aprakstītas literatūras analīzē piemērotas sezonālām laikrindām metodes SARIMA un Holt-Winters nebūs izmantoti eksperimentā. Savā starpā būs salīdzināti naivā prognoze, vienkāršā eksponenciālā izlīdzināšana, ARIMA un LSTM modelis. Naivā prognoze tiek iekļauta kā vienkāršs modelis, pret kuru salīdzina pārējās metodes (Rosenblad, 2021). Detalizētāk par naivo metodi ir uzrakstīts tai veltītā sadaļā.

4.3. Pārdošana un piegādes kā analīzes objekti

No prognozēšanas viedokļa pārdošanas un piegādes datiem ir atšķirīga loma. Pārdošanas apjomi atspoguļo faktisko pieprasījumu un tāpēc dabiski kļūst par prognozēšanas galveno uzmanības objektu. Savukārt piegāžu apjomi raksturo krājumu papildināšanu un ir atkarīgs ne tikai no pieprasījuma, bet arī no iekšējiem lēmumiem un nezināmiem uzņēmuma procesiem. Datubāzē ir redzami pārdošanas un piegāžu apjomi. Pārdošanas ierakstu ir desmitiem reižu vairāk nekā piegāžu ierakstu, piegāžu ir maz un tās ir ļoti neregulāras. To var ieraudzīt 4.2. attēlā.



4.2. att. Kopējie pārdošanas un piegādes ieraksti pa mēnešiem

Tā kā piegādes veido tik īsu sēriju, tās nav piemērotas kā prognozējošs mainīgais tradicionālajām metodēm. Neironu tīkla pieejā situācija ir citāda, pat retas piegādes var būt noderīgas kā papildu ievades signāls, tas var potenciāli palīdzēt modelim ieraudzīt kādas slēptās atkarības datus. Līdz ar to, šajā darbā piegādes dati ir uzskatīti vienkārši

kā papildinformācija, tomēr turpmākajā darbā, tie potenciāli var veidot atsevišķu prognozēšanas uzdevumu.


4.4. Pārdošanas apjoma trūkums individuālā materiāla līmenī un apkopošanas līmeņa izvēle

4.3. sadaļā tika konstatēts, ka pieejamie dati, iespējams, sākotnēji bija pārvērtēti, un prognozētais mērķis ir jāpārskata. Tika ieteikts pāriet no atsevišķu materiālu pārdošanas apjomu prognozēšanas uz apkopotu materiālu grupu pārdošanas apjomu prognozēšanu. Formāli pieejami dati ļauj veidot laika rindu katram materiālam atsevišķi. Tomēr, analizējot pārdošanas apjomu sadalījumu pa mēnešiem, kļuva skaidrs, ka šādā līmenī vairums gadījumu nav piemērots apmācībai: ievērojamai daļai materiālu pieejamā periodā nav pārdošanas vispār vai arī tie tiek pārdoti reti. 88 no 206 materiāliem datubāzē nav reģistrēts neviens pārdošanas mēnesis (skat. 4.2. tab.). Mediānais materiāls tiek pārdots tikai divos no deviņiem mēnešiem (neiekļaujot aprēķinā materiālus bez pārdošanas apjomiem), kā redzams 4.3. attēlā. Tikai ļoti neliels skaits materiālu uzrāda pārdošanas apjomus lielākajā daļā pieejamo mēnešu. Izmantojot atsevišķus materiālus kā galveno prognozēšanas mērķi, modeļu salīdzinājumi tiktu veikti, izmantojot pārāk īsas un retas laika rindas.

4.2. tabula

Materiālu sadalījums pēc pārdošanas mēnešu skaita

Mēnešu skaits ar vismaz vienu pārdošanas darījumu	Materiālu skaits
0	88
1	50
2	27
3	14
4	11
5	8
6	6
8	2



4.3. att. Materiālu mēnešu skaits ar pārdošanas apjomiem ar mediānu

Šādi dati ir neērti ne tikai tradicionālajām metodēm, bet pat salīdzināšanai. Ja prognoze ir balstīta uz individuāliem datiem, tradicionālās metodes tiks novērtētas, izmantojot ļoti retus, nestabilus datu kopumus. Šajā gadījumā salīdzināšanas rezultāts būs atkarīgs nevis no modeļa kvalitātes, bet gan no tā veiksmes trāpīt retam pārdošanas mēnesim. Tas padara secinājumus par metožu salīdzināšanu pārāk vājus.

Tāpēc bija nolemts izmantot plašāko prognozēšanas mērķi – zīmola+kategorijas grupas. Šo izvēli motivēja divi iemesli. Pirmkārt, viena un tā pati kategorija var parādīties dažādiem zīmoliem, tāpēc atsevišķu kategorijas izmantošana tikai kā analīzes vienība varētu izraisīt kļūdas vai pārpratumus. Otrkārt, apkopojums pēc zīmola+kategorijas samazina rindu retumu: atsevišķu materiālu reti pārdošanas apjomi vienas grupas ietvaros tiek summēti, padarot sēriju stabilāku. Tā var pārliccināties, apskatot 4.3. tabulu.

4.3. tabula

Zīmolu+kategoriju grupas un mēnešu skaits ar pārdošanas apjomiem, kas nav nulle

Zīmols+kategorija	Pārdošanas mēnešu skaits	Kopējais pārdošanas apjoms, m3
BUVNIEKS: NEĒVELĒTI	8	142.16
KARTEX: APDARES DĒĻI	8	22.243
KARTEX: TERASES DĒĻI	7	11.326
BUVNIEKS: ĒVELĒTI	7	11.32

KARTEX: KOKMATERIĀLI	7	9.931
KARTEX: KARKASS	7	2.237
KARTEX: ŽOGA DĒĻI	6	1.934
RONDI: C24	4	22.915
KARTEX: GRĪDAS DĒĻI	4	0.869
KARTEX: PIRTS	2	0.207
KARTEX: LĪSTE	0	0
KARTEX: DAŽĀDAS PRECES	0	0.0

Ar sarkano fonu ir parādītas grupas, kas tiks izslēgtas; par to ir rakstīts zemāk

Pēc šīs apkopošanas izrādījās, ka datus bija ierobežots, bet jau analīzei piemērots grupu skaits, kurās pārdošanas apjomi tika novēroti relatīvi regulāri. Tas padara zīmola+kategorijas pārdošanas prognozēšanu piemērotāku nekā atsevišķu produktu līmeni. Šis risinājums pietiekami labi atbilst uzņēmuma praktiskajām vajadzībām un padara šo darba metožu salīdzinājumu statistiski jēgpilnu.

Tomēr pat pēc pāriešanas uz zīmola+kategorijas līmeni ne visas grupas ir vienlīdz piemērotas prognozēšanai. Dažas grupas joprojām rada pārdošanas apjomus. Tāpēc turpmākai eksperimentēšanai ir nepieciešama papildu grupu atlase. Autors nolēma galvenajā eksperimentā iekļaut tikai tās zīmolu+kategoriju grupas, kurās pārdošanas apjomi tika novēroti lielākajā daļā pieejamo mēnešu. Tas nozīmē, ka apmācībā jāiekļauj pārdošanas apjomi, kas nav nulle, vismaz sešos no deviņiem mēnešiem. Šis ierobežojums nav ieviests kā universāls noteikums, bet gan kā darba atlases kritērijs, kas balstīts uz datu struktūru. Citiem vārdiem sakot, eksperimentā būs iekļautas tikai tās grupas, kurās pārdošanas apjomi ir novēroti pietiekami regulāri, lai sērijā būtu vismaz minimāla pārdošanas dinamika, pārējās grupas būs izslēgtas. Grupa "DAŽĀDAS PRECES" ir īpaši izslēgta, jo tā apvieno pārāk dažādus produktus un neveido jēgpilnu prognozēšanas mērķi. Pat ja šādu grupu formāli varētu saglabāt datubāzē, no prognozēšanas viedokļa tā neatspoguļo stabilu pieprasījuma veidu.

4.5. Prognozētā mainīgā izvēle un rindu konstruēšanas noteikumi

Primārais prognozes mainīgais ir *sale_m3* – pārdošanas apjoms kubikmetros. Bija pieņemts šāds lēmums, jo kokmateriālu iepirkumi ir mērīti kubikmetros. Turklāt, ir jāprognozē nākamajam periodam nepieciešamais kokmateriālu daudzums. Lai gan tas var šķist ne īpaši informatīvi zīmola+kategorijas grupas līmenī, šī darba kontekstā tas ir pietiekams. Ja dati būtu pilnīgāki, būtu piemērotāk prognozēt atsevišķu materiālu

pārdošanas apjomus, izmantojot kolonnu *sale_pcs*, bet tas ir atstāts turpmākajam darbam. Līdzīgi *sale_eur* atspoguļo arī cenu ietekmi: tas sastāv no cenu izmaiņām, atlaidēm utt., un tāpēc ir mazāk piemērots kā galvenais mainīgais.

Šajā pētījumā rindu konstruēšanai tiek izmantots mēneša laika solis. Katrai izvēlētajai zīmola+kategorijas grupai tiek ģenerēta vērtību secība mēnešiem no 2025. gada jūlija līdz 2026. gada martam, to fragmentu var ieraudzīt 4.4. tabulā, pilno tabulu var apskatīt 2. pielikumā. Ja attiecīgajā mēnesī konkrētajai grupai netiek reģistrēti pārdošanas apjomi, tiek pieņemts, ka pārdošanas apjoms ir nulle. Šis noteikums ir pieņemams tieši apkopotu grupu līmenī, jo mēnesis joprojām ir daļa no kopējā novērošanas perioda, vienkārši bez pārdošanas darījumiem. Tomēr, ja šim darbam būtu pieejams plašāks datu kopums, varētu apsvērt atsevišķu nedēļu vai pat dienu prognozēšanu, kas atkal ir atstāts turpmākajam darbam.

4.4. tabula

Pārdošanas apjoma tabula pēc mēneša un materiālu grupas (fragments)

	Zīmols: kategorija	Mēnesis	Pārdošanas apjoms <i>sale_m3</i>
1.	BUVNIEKS: NEĒVELĒTI	2025-07	0
2.	BUVNIEKS: NEĒVELĒTI	2025-08	20.762
3.	BUVNIEKS: NEĒVELĒTI	2025-09	36.76175
4.	BUVNIEKS: NEĒVELĒTI	2025-10	14.9934
5.	BUVNIEKS: NEĒVELĒTI	2025-11	33.86992
...			
106.	RONDI: C24	2026-01	0
107.	RONDI: C24	2026-02	0
108.	RONDI: C24	2026-03	12.33225

4.6. Prognozēšanas problēmas galīgais izklāsts

Balstoties uz datu analīzi, var formulēt galīgo prognozēšanas problēmas apgalvojumu. Pirmkārt, tika izvēlēta zīmola+kategorijas materiālu grupas kā prognozes mērķi. Šis lēmums ir balstīts uz faktu, ka atsevišķu materiālu līmenī rindas bija pārāk mazas, vairumā gadījumu pārdošanas apjomi tiek reģistrēti tikai vienu vai dažus mēnešus, kas apgrūtina metožu apmācību un rezultātu salīdzināšanu. Apkopošana zīmola+kategorijas līmenī to uzlabos.

Otrkārt, tika izvēlēta *sale_m3* kolonna – pārdošanas apjoms kubikmetros – kā galveno (jeb mērķa) prognozes mainīgo. Tas ir vissaprātīgāk no uzņēmējdarbības viedokļa, jo uzņēmuma koksnes iepirkumi tiek mērīti kubikmetros.

Treškārt, galvenajā eksperimentā par piemērotam apmācībai tika uzskatītas tās grupas, kurās pārdošana novērota vismaz sešos no deviņiem mēnešiem. Tas izslēdz rindas, kas ir pārāk vājas.

Ceturtkārt, pārdošanas apjomi tiks prognozēti vienu mēnesi uz priekšu. Ar deviņu mēnešu pieejamajiem datiem tas ir tehniski vispiemērotākais. Ilgāki vai īsākie prognozēšanas periodi būtu mazāk ticami ierobežotā datu apjoma dēļ.

Visbeidzot, galvenie aplūkotie modeļi būs naivā prognozēšana, vienkāršā eksponenciālā izlīdzināšana, ARIMA un LSTM.

5. PROGNOZĒŠANAS METOŽU REALIZĀCIJA UN SALĪDZINĀŠANA

5.1. Eksperimenta iestatīšana

Tā kā prognozēšanas dati veido laika rindu, modeļu novērtēšanā jā saglabā hronoloģiskā secība: katrā pārbaudē modelis ir apmācīts tikai ar iepriekšējiem mēnešiem un testēts nākamajā mēnesī. Šāda pieeja novērš situāciju, kurā modelis netieši izmanto nākotnes informāciju. Ņemot vērā deviņu mēnešu datu ierobežojumu, tika izvēlētas trīs secīgas testēšanas kombinācijas: 2026. gada janvāris, februāris un marts. Mazāks testēšanas mēnešu skaits dotu pārāk šauru novērtējumu, savukārt lielāks testēšanas mēnešu skaits pārāk samazinātu pirmo apmācības periodu. Tāpēc trīs testēšanas mēneši bija izmantoti kā kompromiss starp pietiekamu apmācības vēsturi un vairāku viena mēneša prognožu novērtēšanu. Citiem vārdiem sakot, modeļi bija apmācīti trīs reizes no jaunā katram testa mēnesim, kas nozīmē, ka jauns LSTM bija izveidots katrām testam. Šajā darbā šīs datu sadalījums ir apzīmētas (kodā, aprakstos) kā “*train/test split*”:

- apmācība ar datiem no 2025. gada jūlija līdz 2025. gada decembrim un testēšana 2026. gada janvārī;
- apmācība ar datiem no 2025. gada jūlija līdz 2026. gada janvārim un testēšana 2026. gada februārī;
- apmācība ar datiem no 2025. gada jūlija līdz 2026. gada februārim un testēšana 2026. gada martā.

Tādējādi katrā nākamajā eksperimentā tiek izmantots nedaudz vairāk apmācības datu un pārbaudīta nākamā mēneša prognoze. Tā kā eksperimentā ir izmantotas septiņas materiālu grupas un trīs testēšanas mēneši, katra metode prognozes 21 gadījumus. Šie gadījumi tālāk tiek izmantoti kļūdu rādītāju aprēķināšanai un metožu salīdzināšanai.

5.2. Naivā prognoze

Šajā darbā naivā prognoze tiek izmantota kā bāzes metode (*baseline*) salīdzināšanai ar citām metodēm. Ja sarežģītāks modelis nedarbojas labāk par naivo metodi vai uzrāda līdzīgus rezultātus, tad tā praktisko priekšrocību dotajā datu kopā

nevar uzskatīt par apstiprinātu. Priekšrocība būs apstiprināta, ja sarežģītākais modelis kļūdīsies mazāk par naivo visos trijos testos pēc izvēlētajām metrikām.

Naivās prognozes metode ir realizēta kā vienkārša prognozēšanas metode, kurā testa mēneša vērtība tiek pieņemta kā vienāda ar pēdējā apmācības mēneša faktisko vērtību. Tas atkārto Rosenblada (2021) pieeju, izmantojot līdzīgu formulu:

$$\hat{y}_t = y_{t-1}, \quad (5.1)$$

kur t – laika moments;

$\hat{y}_t$ – šī mēneša prognoze;

y_{t-1} – iepriekšējā mēneša faktiskā vērtība.

Tas ir, prognozējot 2026. gada janvāri, tika izmantota 2025. gada decembra vērtība, prognozējot 2026. gada februāri, tika izmantota 2026. gada janvāra vērtība, un prognozējot 2026. gada martu, tika izmantota 2026. gada februāra vērtība.

Naivās metodes rezultātu piemēru var redzēt 5.1. tabulā. Pilno tabulu var apskatīt 3. pielikumā.

5.1. tabula

Naivās metodes rezultāta piemērs

material_group	test_month	actual	prediction	abs_error
BUVNIEKS: NEĒVELĒTI	2026-01	2.411	16.863	14.451
BUVNIEKS: ĒVELĒTI	2026-01	0.878	0.059	0.818
...				
KARTEX: TERASES DĒĻI	2026-03	1.579	0	1.579
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.054	1.216

5.3. Vienkāršā eksponenciālā izlīdzināšana

Vienkāršā eksponenciālā izlīdzināšana (*Simple Exponential Smoothing* jeb *SES*) ir tradicionāla laika rindu prognozēšanas metode, kurā tiek atjaunināts rindas izlīdzinātais līmenis, izmantojot jaunāko novērojumu un iepriekšējo izlīdzināto vērtību (Rosenblad, 2021). Formāli metodi var pierakstīt šādi:

$$\hat{y}_{t+1} = l_t = \alpha y_t + (1 - \alpha)l_{t-1}, \quad (5.2)$$

kur α - izlīdzināšanas koeficients;

l_t - izlīdzinātais rindas jeb rindu līmenis;

y_t - faktiskā vērtība laika momentā t ;

Lai pielietotu metodi, dati tika iegūti no iepriekš apspriestās SQLite datubāzes. Šajā posmā kopējais pārdošanas apjoms (*sale_m3*) ir aprēķināts katrai zīmola+kategorijas grupai un katram mēnesim no 2025. gada jūlija līdz 2026. gada martam (kā 4.4. tabulā). Sākotnēji tika iegūti 108 ieraksti jeb 12 zīmola+kategorijas grupas ar deviņiem mēnešiem katrā grupā. Pēc 4.3. tabulā definēto filtru pielietošanas tika atlasītas 7 grupas, kas kopā veidoja 63 mēneša novērojumus, katrā atlasītajā grupā – deviņi mēnešu novērojumi. Rezultāti tika grupēti pēc grupas nosaukuma, veidojot atsevišķu viendimensiju laika rindu ar mēneša soli, ko tagad var izmantot kā modeļu ievadi.

Metode tika ieviesta Python valodā, izmantojot *statsmodels* bibliotēku, kurā vienkāršo eksponenciālo izlīdzināšanu īsteno *SimpleExpSmoothing* klase. Izlīdzinātais rindas līmenis l_t un izlīdzināšanas parametrs α tika noteikti automātiski, izsaucot *fit()* metodi. Pēc tam ar *forecast(l)* metodi tika konstruēta testa mēneša prognoze. Parametrs l nozīmē, ka modelis prognozē vienu nākamo periodu. Šī procedūra tika secīgi piemērota visām atlasītajām grupām un visiem trim testiem. Vienkāršas eksponenciālās izlīdzināšanas rezultāta piemēru var redzēt 5.2. tabulā. Pilno tabulu var apskatīt 4. pielikumā.

5.2. tabula

Eksponenciālās izlīdzināšanas rezultāta piemērs

material_group	test_month	actual	prediction	abs_error
BUVNIEKS: NEĒVELĒTI	2026-01	2.411	20.542	18.13
BUVNIEKS: ĒVELĒTI	2026-01	0.878	1.725	0.848
...				
KARTEX: TERASES DĒĻI	2026-03	1.579	1.218	0.36
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.083	1.187

5.4. ARIMA modelis

ARIMA modeli definē trīs nenegatīvu veselu skaitļu parametri: p , d un q (Zhang, 2003). Parametrs p nosaka, cik iepriekšējo rindu vērtību tiek izmantotas, lai prognozētu nākamo vērtību. Parametrs d norāda diferenciācijas kārtu, kas nosaka, vai modelis tiek veidots, izmantojot rindas neapstrādātās vērtības, to izmaiņas vai to izmaiņu izmaiņas utt. Šī darba kontekstā d nosaka, vai pāriet no pārdošanas līmeņiem uz to atšķirībām. Parametrs q nosaka, vai modelis ņem vērā kļūdas, kas radušās iepriekšējos posmos apmācības procesa laikā.

Pareiza šo trīs parametru kombinācija sniegtu vislabāko modeļa prognozi. Tā kā pareizo ARIMA konfigurāciju nevar iepriekš zināt, katram koda testam tika pārbaudīts p , d un q kandidātu kombināciju kopums, un tika izvēlēta labākā. Labākās konfigurācijas izvēlei tika izmantots AIC kritērijs. Tās standarta formu var uzrakstīt šādi (ArunKumar, et al., 2021):

$$AIC = -2 \ln L(\hat{\theta}) + 2K, \quad (5.3)$$

kur $L(\hat{\theta})$ - ticamības funkcija,

K - aprēķināto modeļa parametru skaits.

Kritērijs tiek aprēķināts, pamatojoties uz pielāgošanas (*fitting*) kvalitāti un iegūtās modeļa konfigurācijas sarežģītību. Tātad, $-2\ln(L)$ norāda, cik labi modelis ir pielāgots, un $2k$ ir sods par sarežģītību (parametru skaits, jo vairāk, jo sarežģītāk). ARIMA kontekstā sarežģītība attiecas uz risku, ka konfigurācija ir pakļauta pārmērīgai pielāgošanai (*overfitting*) – scenārijam, kurā modelis ir tik labi apguvis datus, ka tas sāk uztvert "troksni", nevis likumsakarības. Tas nozīmē, ka testa datus modelis darbosies sliktāk nekā citā konfigurācija ar nedaudz sliktāku pielāgošanas kvalitāti, bet zemāku sarežģītību. Zhang (2003) norāda, ka pārmērīgi pielāgots modelis var labi prognozēt apmācības datus, bet sliktāk – jaunus, līdz šim momentam neredzētās.

Līdz ar to kodā katram apmācības ciklam katrai materiālu grupai bija mēģināts atrast labāko ARIMA konfigurāciju pēc AIC. Ja bibliotēka nevarēja pareizi novērtēt konkrētu konfigurāciju, tā to izlaida. Modelis ar zemāko AIC vērtību bija izmantots nākamā mēneša prognozei. Tādējādi katrai materiālu grupai tika noteikta sava ARIMA konfigurācija.

Konfigurācija $\{0,0,0\}$ tika saglabāta kā vienkāršākā iespēja pašā ARIMA saimē. d vērtības tika ierobežotas tikai ar 0 un 1, jo īsām rindām $d = 2$ izmantošana nozīmētu jau bez tā ierobežotās informācijas vēl vairāku zaudēšanu. p vērtības arī bija

ierobežotas ar 0 un 1, un 2 tika saglabāta tikai vienā iespējā, lai pārbaudītu, vai ilgāka autoregresīvā atmiņa sniedz praktiskus uzlabojumus. q vērtības tika iekļautas vairākās iespējās, jo pat prognozējot vienu mēnesi, ir lietderīgi ņemt vērā ne tikai rindas iepriekšējās vērtības, bet arī modeļa iepriekšējo kļūdu struktūru. Šī parametra noteikšanai nav sistemātiska noteikuma (Zhang, 2003). Rezultātā tika pārbaudīta šāds kandidātu kombināciju kopums:

5.3. tabula

Kandidātu kombināciju kopums

	p	d	q
1	0	0	0
2	0	0	1
3	0	1	0
4	0	1	1
5	0	1	2
6	1	0	0
7	1	0	1
8	1	1	0
9	1	1	1
10	2	1	0

Implementācijai bija izmantota tā pati bibliotēka, kas bija izmantota SES metodei, tāpēc pieeja un metodes palika nemainīgas; kods atšķīrās tikai noteiktos modeļa parametros. Veidojot ARIMA, papildus tika izmantoti parametri *enforce_stationarity=False* un *enforce_invertibility=False*. Pirmais parametrs izslēdz stingro stacionaritātes prasību modeļa autoregresīvajai daļai, bet otrais – stingro invertējamības prasību slīdošā vidējā daļai (statsmodels developers, n.d.). Šīs implementācijas kontekstā tas tika darīts kā tehnisks lēmums: atstājot šos ierobežojumus iespēžotus, bibliotēka novērtēšanas fāzē būtu noraidījusi dažas kandidātu konfigurācijas. Īsu datu dēļ un tā kā pielāgošana bija veikta ierobežotam variantu kopumam, to bija nolemts darīt manuāli bez papildu automātiskiem filtriem, bet gan izmantojot AIC. Modeļa rezultāta piemēru var redzēt 5.4. tabulā. Pilno tabulu var apskatīt 5. pielikumā.

5.4. tabula

ARIMA rezultāta piemērs

material_group	test_month	actual	prediction	abs_error	order
BUVNIEKS: NEĒVELĒTI	2026-01	2.411	31.953	29.542	(1, 1, 1)
BUVNIEKS: ĒVELĒTI	2026-01	0.878	2.393	1.515	(0, 1, 2)
...					
KARTEX: TERASES DĒĻI	2026-03	1.579	0	1.579	(2, 1, 0)
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.012	1.258	(1, 0, 1)

order – labāka kandidātu kombinācija

5.5. LSTM neironu tīkls

5.5.1. Neironu tīkls kā regresijas modelis

Vienvirziena neironu tīklu (*feedforward neural network*) var uzskatīt par funkciju, kas pārveido ievades pazīmju vektoru x skaitliskai prognozei y , un to parasti izmanto regresijas un funkciju aproksimācijas uzdevumos (Minnett, Smith, Lennon, & Hecht-Nielsen, 2011). Šādos modeļos izeja tiek veidota kā slēpto vienību lineāra jeb svērtā kombinācija ar nelineārām aktivācijas funkcijām, piemēram, hiperbolisko tangensu, kas ļauj modelēt sarežģītas nelineāras attiecības starp ieejām un izejām (Minnett, Smith, Lennon, & Hecht-Nielsen, 2011).

Mākslīgs neirons pilnībā savienotā (*multilayer*) slānī aprēķina savu ieeju svērtu summu ar pievienotu nobīdi, kam seko nelineāras aktivācijas funkcijas pielietošana. Šo darbību var izteikt šādi (Chiang & Fu, 1992):

$$z = w^T x + b \text{ un } a = \varphi(z), \quad (5.4)$$

kur x ir ieejas vektors,

w ir svaru vektors,

b ir nobīde,

$\varphi(z)$ ir aktivācijas funkcija.

Slānim, kas sastāv no vairākiem neironiem, šo aprēķinu raksta matricas formā. Daudzslāņu perceptronos neironi veido ieejas, slēptajā un izejas slānī, un tīkls mācās, pielāgojot neironu svarus, lai samazinātu kļūdu starp prognozēto un vēlamu izejas vērtību (Ramchoun, Idrissi, Ghanou, & Ettaouil, 2019). Regresijas uzdevumiem izejas

slānis sastāv no viena neirona, kas ģenerē nepārtrauktas vērtības prognozes (Chiang & Fu, 1992). Šajā gadījumā prognozēto izeju var uzrakstīt kā 5.5. formulu (Ramchoun, Idrissi, Ghanou, & Ettaouil, 2019):

$$\hat{y} = W_{\text{out}}h + b_{\text{out}}, \quad (5.5)$$

- kur $\hat{y}$ – prognozētā izejas vērtība;
 W_{out} - izejas slāņa svaru matrica;
 h - pēdējā slēptā slāņa izvades vektors;
 b_{out} - izejas slāņa nobīdes parametrs.

5.5.2. Aktivizācijas funkcijas

Aktivācijas funkcija (5.4. formulā – φ) piešķir tīklam nonlinearitāti, lai uztvertu sarežģītas atkarības datus, ko nevar darīt tradicionālie lineārie modeļi, jo tiem ir ierobežotas aproksimācijas iespējas (Zhang, 2003).

- Sigmoid: $\sigma(z) = \frac{1}{1+e^{-z}}$ – sākotnēji bija populārs, to raksturoja izzūdošie gradienti (Filali, et al., 2022).
- tanh: $\tanh(z)$ ir hiperboliskā pieskares funkcija, ko bieži izmanto slēptajos slāņos (Minnett, Smith, Lennon, & Hecht-Nielsen, 2011).
- ReLU: $\max(0, z)$ ir vienkārša aktivizācijas funkcija, ko plaši izmanto dziļu tīklu ātrai apmācībai (Sirisha, Belavagi, & Attigeri, 2022).

Rekurentās arhitektūrās (tostarp LSTM) nonlinearitātes ir ieviestās neironos ar sigmoidu un tanh, bet regresijas izejā parasti izmanto vienkāršu lineāru transformāciju (Suresh & Suresh, 2023; Sirisha, Belavagi, & Attigeri, 2022). Šāda veida LSTM būs izveidots šajā darbā (kodā).

5.5.3. Tīkla apmācība

Tīkls ir apmācīts, minimizējot zaudējumu funkciju, kas rāda neatbilstību starp prognozēm un faktisko vērtību. N paraugiem funkciju var uzrakstīt šādi:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N L(x_i, \theta), \quad (5.6)$$

- kur θ ir tīkla parametri (svari un nobīdes);
 $L(x_i, \theta)$ - zaudējumu funkcijas vērtība konkrētam paraugam;
 $\mathcal{L}$ - kopējā zaudējumu funkcijas vērtība.

Šīs funkcijas gradienti $-\frac{\partial \mathcal{L}}{\partial \theta}$ – tiek aprēķināti apmācības laikā un izmantoti svaru atjaunināšanai. Neironu tīklos to parasti panāk ar atpakaļizplatīšanas (*backpropagation*) algoritmu, kas aprēķina zaudējumu funkcijas gradientus no tīkla svariem (Ji, 2024; Minnett, Smith, Lennon, & Hecht-Nielsen, 2011).

Regresijas problēmās kā zaudējumu funkcija bieži tiek izmantota vidējā kvadrātiskā kļūda (MSE). Piemēram, to var uzrakstīt šādi (Minnett, Smith, Lennon, & Hecht-Nielsen, 2011):

$$\varepsilon(u, v) = \frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2, \quad (5.7)$$

kur T ir apmācības piemēru skaits,

y_t ir pareizā vērtība,

$\hat{y}_t$ ir tīkla prognoze,

$\varepsilon(u, v)$ – MSE kļūda.

5.5.4. Optimizācija: SGD un adaptīvie optimizētāji

Pēc gradientu aprēķināšanas tīkla parametrus atjaunina optimizētājs, kas izmanto dažādas metodes. Piemēram, tās, kas balstītas uz stohastisko gradientu (SGD). Tos nosaka mācīšanās ātrums (Ji, 2024).

SGD (*stochastic gradient descent*) izmanto gradientus, kas aprēķināti datu kopuma nejauši izvēlētai daļai, lai atjauninātu svarus. *Momentum-SGD* izmanto iepriekšējo gradientu informāciju (gradientu inerci), lai izlīdzinātu svaru atjaunināšanas svārstības. *RMSprop* izmanto eksponenciāli dilstošu gradientu kvadrātu vidējo vērtību. *Adam* apvieno *Momentum-SGD* un *RMSprop* idejas, izmantojot gradienta un gradienta kvadrāta mainīgās vidējās vērtības (Ji, 2024). Eksperimentā izvēlēta konkrētā optimizētāja un zaudējumu funkcijas pamatojums ir apspriests tālāk realizācijas sadaļā.

5.5.5. Pazīmju standartizācija un mērķa vērtības normalizācija

Pastāv divi līdzīgi jēdzieni (Borrouh, Fissoune, & Badir, 2025; Elmotawakkil, Enneya, Bhagat, Ouda, & Kumar, 2025):

- normalizācija un standartizācija ir skaitlisku pazīmju mērogošanas metodes;
- kategorisko pazīmju kodēšana (*embedding*) ir kategorisko mainīgo pārveidošana skaitliskā formā turpmākai izmantošanai modelī.

Abi soļi var atrasties vienā risinājumā, risinot dažādas problēmas. Normalizācija bieži tiek saprasta kā *min-max* mērogošana diapazonā $[0,1]$:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (5.8)$$

Šo normalizācijas veidu izmanto, lai pazīmju vērtības novestu līdz kopējam mērogam (Odukoya, et al., 2022; Borrohou, Fissoune, & Badir, 2025). Normalizācija ir ērta, ja pazīmes ir jānovieto vienā diapazonā, bet *min-max* mērogošana ir jutīga pret novirzēm, jo tā balstās uz novērotajiem pazīmes minimumiem un maksimumiem (Rajesh, Kuppuri, Peter, Reddy, & Sonia, 2025).

Standartizācija samazina pazīmi līdz vidējam rādītājam (nullei) un standartnovirzei (vieniekam) (Elmotawakkil, Enneya, Bhagat, Ouda, & Kumar, 2025; Rajesh, Kuppuri, Peter, Reddy, & Sonia, 2025):

$$x' = \frac{x - \mu}{\sigma}, \quad (5.9)$$

kur μ ir apmācības datu vidējais,

σ ir standartnovirze.

Standartnovirze σ parāda vērtību izkliedi ap vidējo vērtību: jo lielāka σ , jo tālāk ir pazīme (Hu, Hu, Li, & Du, 2023). Standartizācija padara dažādu mērogu pazīmes salīdzināmas, kas atvieglo optimizāciju ar gradientu metodēm (Dick, Owen, & Whigham, 2020).

Darbā tika nolemts izmantot tieši standartizāciju. μ un σ tiek aprēķināti pa asīm (*samples, timesteps*) – tas ir, gan *samples* (šī implementācijā – materiālu grupas), gan *timesteps* (šī implementācijā – periodi) tiek "sakļauti", jo viena pazīme rodas dažādos laika punktos. Pēc tam katrai pazīmei tiek ņemta vidējā vērtība un standartnovirze. Piemēram, kolonnai *sale_m3* būtu aprēķināti savējie μ un σ , ņemot tās no visām grupām visām mēnešiem. Lai izvairītos no dalīšanas ar nulli, ja standartnovirze ir nulle, tā tiek aizstāta ar 1.0.

Ne tikai ievades x , bet arī mērķa mainīgais y ir standartizēts atsevišķi. Tā μ un σ tiek saglabāti, lai pēc tam prognoze tiek atgriezta sākotnējā mērogā, izmantojot tos apgrieztā transformācijā.

Svarīgi atzīmēt, ka laika rindu literatūrā viena no sintētisko datu ģenerēšanas pieejām ietver trokšņa, piemēram, Gausa trokšņa, pievienošanu sākotnējiem datiem, trokšņa skalu izvēloties, pamatojoties uz to pašu standartnovirzi (Hu, Hu, Li, & Du, 2023). Par to ir plašāk runāts 6.1. sadaļā.

5.5.6. Rekurenti tīkli un LSTM atšķirība

Neironu tīkls sagaida fiksētu ievades pazīmju skaitu. Rekurenti neironu tīkli (RNN) ievieš slēptu stāvokli h_t , kas ir atjaunināts soli pa solim un pārnes informāciju no pagātnes. To izmanto priekš laika rindām, kur datus parāda kā laika gaitu (Yunita, et al., 2025).

$$h_t = f(x_t, h_{t-1}), \quad \hat{y}_t = g(h_t), \quad (5.10)$$

kur $f(\cdot)$ ir slēptā stāvokļa atjaunināšanas funkcija,

$g(\cdot)$ ir izejas funkcija, kas pārveido slēpto stāvokli prognozē.

RNN tīkliem ir grūti apgūt liela attāluma atkarības izzūdošo gradientu dēļ atpakaļizplatīšanās laikā (Filali, et al., 2022). Tātad LSTM (*Long Short-Term Memory*) atrisināja to problēmu ar "atmiņas stāvokli" c_t un "vārtiem" (*gates*). Šie vārti kontrolē, kas būs aizmirsts, ierakstīts un izvadīts (Yunita, et al., 2025; Filali, et al., 2022). Tātad LSTM ievieš:

forget gate f_t – cik daudz informācijas no c_{t-1} paturēt,

input gate i_t – cik daudz jaunas informācijas ierakstīt,

candidate $\tilde{c}_t$ – kandidātvērtības ierakstīšanai atmiņā,

output gate o_t – kura atmiņas stāvokļa daļa tiks izvadīta h_t .

Viss tas ir LSTM atmiņas pārvaldības mehānisms (Filali, et al., 2022). Līdz ar to, šajā prognozēšanas uzdevumā, izmantojot LSTM un padodot kā ievadi pazīmju secību, tas ļauj modelim, prognozējot nākamo mēnešu, ņemt vērā vairāku iepriekšējo mēnešu vērtības (Yunita, et al., 2025; Filali, et al., 2022).

5.5.7. Datu sagatavošana

Tagad izprotot RNN un LSTM koncepcijas, var uzrakstīt šī darba implementāciju. Pirmkārt, ir jāsagatavo dati. Šim uzdevumam tika izmantoti divi Python moduļi – Pandas un Numpy. Pandas arī bija izmantots, darbojoties ar tradicionālajām metodēm. Numpy palīdz neironu tīkla modulim, ko izmanto LSTM veidošanai, par ko rakstīts nākamajā nodaļā. To izmanto masīvu sagatavošanai. Pirmkārt, sākotnējie dati ir pārveidoti par (X, y) pāru kopu, izmantojot slīdošo logu (*sliding window*). Kodā šī ir funkcija *build_samples*, kas

1. katrai materiālu grupai ņem apmācības perioda `train_start:train_end` fragmentu. Piemēram, pirmām testam apmācības periods ir no 2025.

gada jūlija līdz 2025. gada decembrim; otrām – līdz janvārim, trešajam – līdz februārim;

2. sadala to fragmentu logos (windows jeb samples) ar garumu $\text{Timestep_Count}=3$ (fiksēts realizācijā), uz kuriem tiks apmācīts un pielāgots modelis;
3. katram logam piešķir mērķa vērtību – nākamā mēneša pārdošanas apjomus. Ar šo pieeju konkrētajā sadalījumā modelis neizmanto attiecīgā testa mēneša vērtību apmācībai, bet tiek apmācīts uz iepriekš pieejamajiem līdzīgiem logiem. Principu var attēlot šādi:

$$X = [t - 2, t - 1, t], \quad y = [t + 1]. \quad (5.11)$$

Autors pievērš uzmanību, ka tās nav trīs pazīmes, kas būs padoti LSTM, bet tie ir trīs laika soļi, kur katrā ir skaitlisku pazīmju kopa. *Tensor* izteiksmē ievades dati izskatās kā (*batch, timesteps, features*). Tas ir tieši atspoguļots modeļa LSTM slāņa parametrā *batch_first=True*.

Zemāk ir visas LSTM nodrošinātās pazīmes. Autors uzsver, ka kopa ir plašāka nekā tradicionālajiem modeļiem. Dažas papildu pazīmes tika aprēķinātas, lai labāk parādītu pieejamo kontekstu un potenciāli atklātu slēptos datu modeļus:

1. *sale_m3* – mēneša pārdošanas apjoms, kas ievades logā tiek izmantots kā vēsturiska pazīme, bet nākamajā mēnesī kā prognozējamais mērķis;
2. *received_m3* – mēneša piegādes;
3. *delta_sale_m3* – pārdošanas apjoma starpība salīdzinājumā ar iepriekšējo mēnesi;
4. *delta_received_m3* – piegāžu apjoma starpība salīdzinājumā ar iepriekšējo mēnesi;
5. *rolling_sales_mean_2* – divu mēnešu pārdošanas apjoma slīdošais vidējais rādītājs (katram mēnesim aprēķināts kā pēdējo 2 mēnešu vidējais);
6. *rolling_sales_mean_3* – trīs mēnešu pārdošanas apjoma slīdošais vidējais rādītājs.

LSTM ir apmācīts uz kopīgas logu kopas, savākta no visām grupām. To var redzēt *build_samples* metodē, kas ģenerē *x* un *y* vērtības visām grupām vienlaikus, pēc kā *train_model* funkcija apmāca vienu modeli uz šīs apvienotās kopas. Šīs pieejas ideja ir tāda, ka, ja atsevišķas laika rindas ir īsas, atsevišķa modeļa apmācība katrai grupai var novest pie nepietiekama apmācības piemēru skaita, līdz ar to apvienotā (*pooled*) pieeja

ļauj izmantot informāciju no visām rindām un atrast kopējas atkarības (Bandara, Bergmeir, & Smyl, 2020). Tomēr, izmantojot šo pieeju, modeli nevar atstāt pilnībā bez informācijas par to, kam pieder laika rinda. Apmācība uz *heterogēnu* laika rindu kopas, kas apvienotas vienā kopā, var izraisīt precizitātes samazināšanos, jo modelis nespēs atšķirt šīs grupas un nebūs pietiekami pielāgots konkrētām rindām (Bandara, Bergmeir, & Smyl, 2020; Abbasimehr, Abri, Oskouei, & Noshad, 2025). Un tad, tā vietā, lai identificētu individuālas attiecības, tas identificētu vidējās atkarības un kļūtu mazāk efektīvs atsevišķu grupu prognozēšanā. Lai atrisinātu šo problēmu, bija nepieciešams kaut kādā veidā iemācīt modelim atšķirt grupas, piemēram, izmantojot klasterizāciju vai papildu pazīmes (Abbasimehr, Abri, Oskouei, & Noshad, 2025).

Šajā pētījumā tika izvēlēts izmantot pieeju ar papildu pazīmēm. Ir trīs iespējamās ieviešanas.

1. Izmantojot kategoriju kodēšanu – grupām tiek piešķirts vesels skaitlis ($0 \dots G-1$). Problēma ir tā, ka, ja modelis šo skaitli var interpretēt kā kārtas vērtību (7. grupa ir lielāka par 3. grupu), pat ja kategorijām nav dabiskas secības (Borrohou, Fissoune, & Badir, 2025).
2. Vienreizēja (*one-hot*) kodēšana – katru grupu attēlo garuma vektors G , kur viens elements ir 1, bet pārējie ir 0. Tas novērš kārtas problēmu, bet padara ievadi retu (Borrohou, Fissoune, & Badir, 2025).
3. Izmantojot iegulšanas (*embedding*) slāni, kurā tiek glabāta katras grupas parametru vai svaru tabula (Santis, Giordano, & Mellia, 2026). Par to jau īsi bija runāts standartizāciju nodaļā.

Tika izvēlēta trešā pieeja. Iegulšanas slānis pārveido kategoriskas vērtības vektoros (tabula $G \times 4$, jo realizācijā `GROUP_EMBEDDING_COUNT=4`), kuros katrai kategorijai atbilst apmācāms vektors ar 4 skaitļiem. Šie vektori tiek pielāgoti apmācības laikā kopā ar pārējiem tīkla parametriem, līdzīgi neironu tīkla svāriem. Šāda reprezentācija arī var atspoguļot līdzības starp kategorijām, jo līdzīgām kategorijām ar laiku potenciāli var veidoties līdzīgi vektori.

5.5.8. Modeļa arhitektūra un apmācība

Galīgais neironu tīkls sastāv no trim galvenajiem komponentēm:

1. LSTM atgriež izvadi katram laika solim;

2. tiek ņemta pēdējā laika soļa (loga pēdējā mēneša) izvade un ar to tiek savienota pašreizējās grupas iegulšana;
3. iegūtais vektors tiek padots lineārā slānī, kas ģenerē pārdošanas prognozi.

Tehniski tas tiek realizēts, izmantojot `torch.cat([lstm_last_timestep_output, groups_embedding], dim=1)` un `nn.Linear(HIDDEN_STATE_SIZE + GROUP_EMBEDDING_COUNT, 1)`.

SalesPredictor klase attēlo visu sistēmu. Tā definē šādas formas modeli:

1. LSTM: `nn.LSTM(input_size=feature_count, hidden_size=16, batch_first=True)`. Modelim ir viens LSTM slānis. Tas ir pamatots kā apzināta modeļa sarežģītības ierobežošana ierobežotu datu apjomu dēļ. Tas samazinās pārmērīgas pielāgošanas risku;
2. grupas iegulšanas daļa:
`nn.Embedding(num_embeddings=group_count, embedding_dim=4);`
3. lineārs izvades slānis: `nn.Linear(16 + 4, 1)`.

Konstantes ir fiksēti faila sākumā: 3 mēnešu logs, slēptā stāvokļa izmērs 16, iegulšanas vektora izmērs 4, 400 epohas apmācībai un mācīšanās ātrums 0,01.

Apmācība notiek, izmantojot `train_model` funkciju. Vispirms tā iestata MSE zaudējumu funkciju (`nn.MSELoss()`). Tika nolemts izmantot MSE, jo tas ir regresijas uzdevums, un, kā bija iepriekš apspriests, MSE zaudējuma funkciju izmanto tieši regresijas uzdevumiem. Līdz ar to modelis kļūst jutīgāks pret lielām kļūdām (ArunKumar, et al., 2021), kas nozīmē, ka svāri tiek atjaunināti agresīvāk un apmācība notiek ātrāk. Kļūda tiek aprēķināta, izmantojot formulu 5.7. Pēc tam tiek inicializēts Adam optimizētājs (kas, kā jau bija teikts, apvieno *Momentum-SGD* ar *RMSprop*), izmantojot `torch.optim.Adam(model.parameters(), lr=LEARNING_RATE)`. Tas tika izvēlēts, jo Ji (2024) atzīmē, ka starp aplūkotajiem algoritmiem Adam konverģē ātrāk nekā citi un parasti praksē darbojas labāk. Visbeidzot, apmācības cikls tiek palaists fiksētam *EPOCHS* epohu skaitam. Apmācība notiek regresijas režīmā: visa sistēma atgriež pārdošanas prognozi nākamajam mēnesim.

Pēc apmācības pabeigšanas tiek izpildīta funkcija `predict_next_month`. Tā ņem pēdējos trīs apmācības perioda mēnešus katrai grupai un standartizē tos ar tām pašām μ un σ vērtībām, kas aprēķinātas apmācības kopai. Ir svarīgi izmantot šīs vērtības, jo, izmantojot citas vērtības, ievades dati tiks mērogoti atšķirīgi no apmācības laikā izmantotajiem datiem, modelis to nepareizi interpretēs un radīs nepareizas prognozes.

Pēc tam modelis ģenerē prognozi standartizētajā skalā, destandartizē to atpakaļ uz sākotnējām mērvienībām un nodrošina, ka rezultāts nav negatīvs, interpretējot negatīvu rezultātu kā nulli ($\hat{y} = \max(\hat{y}, 0)$).

Kopumā eksperiments tiek organizēts kā līdzīgi tradicionālajam metodēm ar to pašu *train/test* sadalījumu. Katram sadalījumam tiek apmācīts jauns modelis, pēc kura katrai grupai tiek veikta prognoze nākamajam mēnesim (OpenAI, 2026). Katrai prognozei tiek aprēķināti tādas pašas kļūdas: absolūtā kļūda *abs_error*, kvadrātiskā kļūda *sq_error* un relatīvā kļūda *ape*. Rezultāta piemēru var redzēt zemāk. Pilnu rezultātu var atrast 6. pielikumā.

5.5. tabula

LSTM rezultāta piemērs

material_group	test_month	actual	prediction	abs_error	sq_error
BUVNIKS: NEĒVELĒTI	2026-01	2.411	8.032	5.621	31.598
BUVNIKS: ĒVELĒTI	2026-01	0.878	3.339	2.462	6.061
...					
KARTEX: TERASES DĒĻI	2026-03	1.579	4.09	2.511	6.307
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0	1.27	1.613

5.6. Procentuālās kļūdas ierobežojumi un papildu relatīvās kļūdas rādītāji

Kā minēts iepriekš, modeļi tika novērtēti trīs atsevišķos mēnešos (*train/test split*) katrai materiālu grupai, kā rezultātā katram modelim tika iegūta 21 prognoze. Absolūtā procentuālā kļūda (absolūtā starpība starp faktisko un prognozēto vērtību, dalīta ar faktisko vērtību) ir viegli interpretējama, taču tai izradījies svarīgs ierobežojums: ja faktiskā pārdošanas vērtība ir vienāda ar nulli, procentuālo kļūdu nevar aprēķināt. Tas nozīmē, ka, analizējot datus, vairāku materiālu grupu APE nevarēja aprēķināt, jo tām šajā mēnesī nebija pārdošanas. Galu galā APE varēja aprēķināt tikai 13 no 21 prognozes gadījuma katram modelim. Tāpēc, palauzoties tikai uz APE, daļa testa rezultātu tiek izslēgta no relatīvās kļūdas analīzes. Kokmateriālu pārdošanas kontekstā nulles pārdošanas vērtības nav datu kļūdas, kuras var ignorēt, bet gan dabiska datu kopas

sastāvdaļa. Šī darba kontekstā šo datu punktu ignorēšana ir vēl sliktāka, jo, kā jau minēts iepriekš, viens no galvenajiem darba ierobežojumiem ir pieejamo datu trūkums.

Varētu apgalvot, ka šī iemesla dēļ pastāv arī MAE un RMSE, taču arī tiem ir savas problēmas – tie nav relatīvi. MAE nav mērogojams, 1m^3 kļūda nav vienlīdz svarīga grupai, kas pārdod 1m^3 mēnesī, un grupai, kas pārdod 100m^3 mēnesī. RMSE piešķir papildu svaru lieliem neveiksmēm, kas liecina par nestabilitāti, bet nelielā testa kopā liek lielām prognozēšanas kļūdām dominēt metrikā.

Lai risinātu šos ierobežojumus, šajā darbā tika nolemts izmantot papildu relatīvās kļūdas rādītājus. Autors ierosina aprēķināt APE nedaudz atšķirīgi, nosaucot to par pielāgotu APE. To aprēķina, dalot katra prognozes gadījuma absolūto kļūdu ar atbilstošās materiālu grupas kopējo faktisko pārdošanas apjomu testa mēnešos. Tas nodrošina, ka katrai prognozei tiks aprēķināts APE, jo nevienai materiālu grupai nav nulles pārdošanas apjoma visos trijos testa mēnešos.

$$CustomAPE_{g,t} = \frac{|y_{g,t} - \hat{y}_{g,t}|}{\sum_{t \in T} y_{g,t}} = \frac{|y_{g,t} - \hat{y}_{g,t}|}{y_{g,feb} + y_{g,mar} + y_{g,jan}}, \quad (5.12)$$

kur $y_{g,t}$ ir materiālu grupas g faktiskais pārdošanas apjoms t mēnesī,

$\hat{y}_{g,t}$ ir prognozētā vērtība,

T ir prognozēto mēnešu kopa.

Citiem vārdiem sakot, šis rādītājs parāda, cik liela ir mēneša prognozes kļūda, salīdzinot ar materiālu grupas kopējo faktisko pārdošanas apjomu visā prognozes periodā. Tas aprēķina relatīvu kļūdu pat tad, ja faktiskā vērtība individuālai prognozei ir nulle. Tomēr, tā kā saucējs ir kopējais faktiskais pārdošanas apjoms visā prognozes periodā, aprēķina rezultāts kļūst mīkstāks, palielinoties testa sadalījuma skaitam. Piemēram, ja testa periods tiktu pagarināts no trim mēnešiem līdz lielākam skaitlim (kas ir biežāk sastopams, ja neironu tīkla apmācībai ir pieejami lielāki datu kopumi; vai ko var ieviest turpmākajā darbā), saucējs palielinātos, būtībā samazinot relatīvās kļūdas vērtību pat tad, ja mēneša prognozes kvalitāte neuzlabotos. Tāpēc šis rādītājs tikai uzlabo modeļu izskatu, kas nav godīgs salīdzinājums. Šī rādītāja rezultāti ir parādīti beigu 5.6. tabulā.

Šī iemesla dēļ tika ieviests vēl viens rādītājs, kas novērtē kļūdu materiālu grupas līmenī, summējot visas grupas absolūtās kļūdas prognozes periodā un dalot šo vērtību ar tās pašas grupas kopējo faktisko pārdošanas apjomu. Šāda veida rādītājs ģenerē septiņas vērtības, pa vienai katrai grupai:

$$CustomAPE_g = \frac{\sum_{t \in T} |y_{g,t} - \hat{y}_{g,t}|}{\sum_{t \in T} y_{g,t}} = \frac{|y_{g,feb} - \hat{y}_{g,feb}| + |y_{g,mar} - \hat{y}_{g,mar}| + |y_{g,jan} - \hat{y}_{g,jan}|}{y_{g,feb} + y_{g,mar} + y_{g,jan}} \quad (5.13)$$

Šis rādītājs parāda, cik liela ir materiālu grupas kopējā prognozēšanas kļūda salīdzinājumā ar tās pašas grupas kopējo faktisko pārdošanas apjomu prognozēšanas periodā. Tas atrisina pielāgotā APE problēmu, jo gan skaitītājs, gan saucējs tiek aprēķināti vienā un tajā pašā periodā. Tomēr šis rādītājs arī nav īsti piemērots kā galvenais salīdzināšanas kritērijs, jo grupām ar nelielu kopējo faktisko pārdošanas apjomu pat neliela absolūtā kļūda var radīt ļoti lielu procentuālo kļūdu. Tāpēc ar šo rādītāju ir labāk vērtēt atsevišķas grupas, nevis kopējo modeli. Rezultāti ir parādīti arī 5.6. tabulā.

Tika konstatēts, ka otrais rādītājs ir ļoti līdzīgs jau izmantotajam (5.6. tabula) prognozēšanas rādītājam WAPE, ko sauca arī par svērto vidējo absolūto procentuālo kļūdu (WMAPE). WMAPE prognozēšanas pētījumos ir izmantots kā mērogneatkarīgs prognozēšanas precizitātes rādītājs, un to aprēķina kā vidējo absolūto kļūdu, dalītu ar vidējo faktisko vērtību (Forbes, 2021). Šajā darbā WAPE un WMAPE ir viens un tas pats un ir aprēķināti kā:

$$WAPE = \frac{\sum_g \sum_{t \in T} |y_{g,t} - \hat{y}_{g,t}|}{\sum_g \sum_{t \in T} y_{g,t}} \quad (5.14)$$

Vienkārši sakot, WAPE parāda, cik liela ir modeli vai metodes kopējā absolūtā prognozes kļūda, salīdzinot ar kopējo faktisko pārdošanas apjomu visā testa kopā. Tā kā nav nepieciešama dalīšana ar katru atsevišķo faktisko vērtību, prognožu gadījumi ar nulles mēneša pārdošanas apjomu joprojām tiek iekļauti novērtējumā. WAPE arī novērš divu iepriekšējo metriku radītās problēmas, jo atšķirībā no tiem tas ietver visus 21 prognozes gadījumu, novērš dalīšanas ar nulli problēmu un tā rezultātu neietekmē testa sadalījuma apjoms. Tāpēc šis rādītājs galvenokārt turpmāk tiks izmantots modeļu salīdzināšanai, lai gan tiek parādīti arī citi rādītāji. Aprēķinātie WAPE rezultāti ir parādīti 5.6. tabulā.

5.7. Metožu salīdzinājums un starpsecinājumi

Lai salīdzinātu prognozēšanas metodes, katrs modelis ģenerēja viena mēneša prognozes tām pašām materiālu grupām un tiem pašiem trim testa mēnešiem (*train/test split*). Salīdzināšana atspoguļos to, cik piemērota katra metode bija pašreizējam uzņēmuma datu kopumam. Lasītājiem jāpatur prātā arī atšķirība modeļa ievades datos: tradicionālajām metodēm tika doti tikai vēsturiskie pārdošanas apjomi, savukārt LSTM

modelim papildus tika iedotas piegādes, pārdošanas un piegāžu pirmās starpības, kā arī divu un trīs mēnešu slidošie pārdošanas vidējie rādītāji. Tomēr šī atšķirība ir arī daļa no salīdzinājuma mērķa – viena no galvenajām idejām, kas pamatoja LSTM izmantošanu šajā darbā, bija parādīt, ka modelis var apstrādāt plašāku ievades struktūru, tādējādi tika sagaidīts, ka tas sasniegs labāku prognozēšanas precizitāti.

Apkopotie novērtēto metožu rezultāti ir parādīti 5.6. tabulā. MAE un RMSE ir izteikti kubikmetros, savukārt MAPE, pielāgotie procentuālie rādītāji un WAPE ir izteikti procentos. Galīgais rangs ir balstīts uz WAPE.

5.6. tabula

Prognozēšanas metodes rezultātu salīdzinājums

Modelis	MAE, m³	RMSE, m³	MAPE, 13/21 gadījumiem, %	Pielāgots MAPE, %	Grupām pielāgots WAPE, %	WAPE, %
Naive	1.717	3.731	122.94	76.59	229.74	130.3
SES	2.628	5.181	317.51	231.79	695.36	199.4
ARIMA	2.969	7.008	334.73	274.99	824.94	225.3
LSTM	3.359	4.673	619.23	250.87	752.61	254.9

Ar zaļo fonu ir atzīmētā metode ar labāko WAPE vērtību

Saskaņā ar WAPE datiem, labākais rezultāts tika iegūts ar naivo metodi. Tas nozīmē, ka pašreizējam datu kopumam, izmantojot iepriekšējā mēneša pārdošanas vērtību kā nākamā mēneša prognozi, tika iegūta mazāka kopējā relatīvā kļūda nekā SES, ARIMA un LSTM. Šis rezultāts nav tik pārsteidzošs pieejamo datu kontekstā, laikrindas pat neaptver pilnu gada sezonālo ciklu. Šādos apstākļos vienkāršāka metode var būt stabilāka nekā sarežģītāka, kas cenšas ņemt vērā gan tendences, gan izlīdzināšanas uzvedību, gan nelineāras attiecības u. tml. no neliela datu kopuma.

SES metode pēc WAPE datiem deva otro labāko rezultātu. Tas liecina, ka pārdošanas vēstures izlīdzināšana neatklāja daudz papildu informācijas. Vairākas materiālu grupas uzrāda neregulāras ikmēneša izmaiņas un mēnešus ar nulles pārdošanas apjomu – šādos apstākļos izlīdzināts vēsturiskais līmenis turpinās prognozēt pozitīvus pārdošanas apjomus, lai gan patiesībā to nav, un reaģēs pārāk lēni uz pēkšņām izmaiņām (vēl viens iemesls, kāpēc LSTM saņēma pārdošanas pirmās starpības un slidošos pārdošanas rādītājus – lai ātrāk pielāgotos pēkšņām izmaiņām). Līdzīgi novērojumi ir konstatēti arī literatūrā norādītos prognozēšanas salīdzinājumos, kur sarežģītākas vai vispārīgākas metodes ne vienmēr pārspēj vienkāršākas bāzes

metodes. Rosenblad (2021) parāda, ka vienkārša eksponenciālā izlīdzināšana var pārspēt sarežģītākas ARIMA konfigurācijas.

ARIMA modelis uzrādīja vājākus rezultātus nekā gan naivā, gan SES metode. Atkal, šis rezultāts nenozīmē, ka ARIMA kopumā nav piemērots pārdošanas prognozēšanai. Tas tikai norāda, ka modelis šajā darbā nav darbojies pietiekami labi. Tāpat kā citi, rezultāts, visticamāk, ir saistīts ar pieejamo datu īso un neregulāro struktūru.

LSTM modelis uzrādīja vājāko WAPE rezultātu. Tas parāda, ka piekļuve plašākam ievades pazīmju kopumam nekā tradicionālajām metodēm automātiski nenodrošina labāku prognozēšanas kvalitāti. LSTM modeļiem parasti ir nepieciešams pietiekami daudz apmācības piemēru, lai atklātu tās lineāras atkarības, par ko bija runāts iepriekš. Pašreizējā eksperimentā apmācības piemēru skaits bija ierobežots, un arī materiālu grupu skaits un nulles pārdošanas gadījumi padarīja prognozēšanu vēl nestabilāku. Tā rezultātā modelis dažreiz prognozēja pārdošanas apjomus, kad to nebija, un nepamanīja vairākas lielas pieprasījuma izmaiņas, kā rezultātā WAPE vērtība bija tik slikta. Tāpēc LSTM rezultāts nevar pietiekami pierādīt, ka neironu tīkli ir piemēroti šim uzdevumam.

Rezultāti arī parāda, kāpēc modeļi jāvērtē pēc vairākiem rādītājiem, nevis tikai viena. MAE un RMSE parāda prognozēšanas kļūdas absolūto lielumu kubikmetros, nevis relatīvo (tomēr pēc šiem rādītājiem naivā metode joprojām ir labākā). RMSE atklāj, ka ARIMA bija vairākas lielas kļūdas. MAPE tika aprēķināts tikai 13 no 21 prognozēm, taču tas nav redzams tabulā.

6. DATU PAPILDINĀŠANA AR SINTĒTISKAJIEM DATIEM

Sākotnējais eksperiments, kas tika veikts 5. sadaļā, pilnībā neapstiprināja LSTM modeļa pārākumu. Tā neveiksme galvenokārt tiek attiecināta uz datu specifiku. Tieši tāpēc darba sākumā bija apspriestas potenciālās datu papildināšanas iespējas – lai labāk apmācītu LSTM un precīzāk prognozētu pārdošanas. Laika rindu papildināšanas pētījumi norāda, ka dziļās mācīšanās metodes ir jutīgas pret apmācības kopas lielumu, tātad datu papildināšanas galvenā ideja būs esošā datu kopuma paplašināšana. Prognozēšanā papildināšana ir pierādījusi savu noderīgāku rezultātu, ja pieejamie dati ir ierobežoti. Tiek arī uzsvērts, ka laika rindu papildināšana nav universāls risinājums, jo katram datu kopumam ir sava struktūra, un papildināšanas metodes ir jāizvērtē, ņemot vērā konkrēto uzdevumu un datus (Wen, et al., 2021).

Liela mēroga mazumtirdzniecības pierādījumi liecina, ka naivās metodes parasti nav spēcīgākais prognozēšanas risinājums: M5 mazumtirdzniecības prognozēšanas konkurencē naivās metodes bija ievērojami mazāk precīzākas nekā citas bāzes metodes, un sezonālitate tika atzīta par kritisku faktoru prognožu precizitātes uzlabošanā (Makridakis, Spiliotis, & Vassilios Assimakopoulos, 2022). Citos pielietotajos pārdošanas prognozēšanas apstākļos mašīnmācīšanās metodes ir pārspējušas dažas modeļus, ja bija pieejami bagātīgāki pieprasījuma dati vai papildu skaidrojošie mainīgie (piemēram, daudzveidīgāka periodiska pieprasījuma vēsture) (Ribeiro & de Castro, 2022). Tieši tāpēc naivās metodes dominance šajā darbā ir attiecināta uz pieejamo uzņēmumu datu ierobežojumiem.

6.1. Datu papildināšanas pieejas

Literatūras analīzes bija pieminētas GAN un SDV PAR metodes. Sarežģītākiem ģeneratoriem (VAE vai GAN balstītiem), ir nepieciešama papildu ģeneratīvs modelis (Demir, Mincev, Kok, & Paterakis, 2021), bet SDV PAR Pulla, Yasarer un Yarbrough pētījumā (2024) neizrādījās kā laba pieeja – 70,94% kopējā kvalitāte, vairāk nekā 50% sintētisko rindu ir identiskas reālajām rindām. Arī lai nodrošinātu uzticamību, tika izslēgtas arī ieraksti ar mazāk nekā desmit novērojumiem, bet šajā darbā katram ierakstam – materiālu grupai – ir tikai deviņi novērojumi. Tāpēc šobrīd pēdējie divi modeļi ir labāk uzskatāmi par nākotnes darbu.

Šajā darbā sintētisko datu eksperiments tika ierobežots ar vienkāršu laika domēna papildināšanu. To ideja ir ģenerēt papildu vērtības no novēroto datu empīriskā sadalījuma, piemēram, izmantojot vidējo vērtību un standartnovirzi. Tomēr lai gan šādu risinājumu ir viegli ieviest, tas ir vājš kā uz prognozēšanu orientēta papildināšanas stratēģija: laikrindu papildināšanas aptaujās šī pieeju sauca par Gausa trokšņi un šo pieeju apraksta kā vienu no vienkāršākajām papildināšanas metodēm, taču tās var novest pie negatīvas mācīšanās, jo tā nesaglabā laika atkarību, tādējādi var ģenerēt nederīgus laika rindu paraugus. Un, tā kā prognozēšanas modelim ir jāapgūst šī laika atkarības, tās trūkums novedīs pie sliktākām prognozēm (Iglesias, Talavera, González-Prieto, Mozo, & Gómez-Canaval, 2023). Šī iemesla dēļ tieša Gausa populācija, netika izvēlēta kā papildināšanas metode.

Cits prognozēšanas pētījums ir parādījis, ka papildināšana, apvienojot sākotnējās rindas vai palielinot to daļu izlasi (Semenoglou, Spiliotis, & Assimakopoulos, 2023), var uzlabot neironu prognozēšanas veiktspēju. Pārveidojot jau novērotos logus, eksperiments var palielināt apmācības piemēru skaitu, saglabājot spēcīgāku saikni ar sākotnējiem datiem, nekā nodrošinātu tikai uz sadalījumu balstīts ģenerators (Semenoglou, Spiliotis, & Assimakopoulos, 2023; Wen, et al., 2021).

Tika atrastas divas vienkāršas papildināšanas stratēģijas (OpenAI, 2026). Pirmā ir logu apvienošana: divi novērotie apmācības logi tiek apvienoti vienā sintētiskā apmācības paraugā, izmantojot vidējo vērtību. Otrā ir lokālā loga izlase: daļa no novērotā loga tiek saglabāta un pēc tam ar interpolācijas palīdzību tiek izstiepta atpakaļ līdz sākotnējam garumam, uzsverot lokālas atkarības, kas citādi varētu palikt nepietiekami pārstāvēti ar sākotnējiem datiem (Semenoglou, Spiliotis, & Assimakopoulos, 2023). Diemžēl, tā kā logi ir tikai 3 mēnešus gari, izstiepšana ir gandrīz bezjēdzīga, jo nav iekšējas laika struktūras, ko varētu stiept. Tādējādi otrā metode šim darbam nav piemērota, atšķirībā no pirmās.

Praktiskai salīdzināšanai papildināšana jāpiemēro tikai LSTM apmācības datiem. Naivās, SES un ARIMA prognozes paliek nemainīgas un turpina kalpot kā fiksētas bāzes modeles no iepriekšējās nodaļas. Datu papildināšanas literatūrā prognozēšanā ir aplūkota neironu modeļu apmācības kopas problēma. Ja tradicionālajos modeļos tika ievietoti sintētiskie mēneši, tas aizmiglotu atšķirību starp bāzes un LSTM un apgrūtinātu salīdzinājuma interpretāciju (Wen, et al., 2021). Tātad jautājums nav par to, vai visas metodes kļūst labākas ar sintētiskiem datiem, bet gan par to, vai neironu modelis uzlabosies, paplašinot tā apmācības kopu.

Novērtēšanas protokols atspoguļo iepriekšējo nodaļu. Tiek saglabāti tie paši slidošie vienu soli uz priekšu sadalījumi un tie paši reālie testa mēneši. Papildināšana tiks veikta tikai apmācības datiem pēc tam, kad reālie dati ir ielādēti un pārveidoti modelim gatavos logos, bet pirms modeļa apmācības. Papildināšana tiks piemērota tikai iegūtajiem un sagatavotajiem datiem. Citiem vārdiem sakot, tiks saglabāta sākotnējā datu kopas (*SQLite* datubāzes veidā) integritāte, autors izvairījies no tā piesārņošanas ar sintētiskiem novērojumiem.

Pēc literatūras izpētes par trūkstošiem datiem sākotnēji tika apsvērta datu imputācijas (*imputation*) ideja kā iespējama pieeja, lai rekonstruētu nepieejamos aprīļa, maija un jūnija novērojumus, atspoguļojot tos ar vēlākiem mēnešiem (attiecīgi oktobri, septembri un augustu). Tomēr literatūrā uzsvērts, ka imputācijas metodes izvēle ir ļoti atkarīga no datu kopas. Imputācija maina slēptās attiecības dotajos datos un tādējādi var mainīt prognozēšanas veikspēju (Ribeiro & de Castro, 2022). Līdz ar to uz nepieejamiem mēnešiem nedrīkst skatīties kā uz vienkāršam trūkstošām vērtībām – tie veseli trūkstošie novērojumi. Šajā gadījumā imputācija balstītos uz ļoti labu izpratni par laika rindu struktūru, to tendenci un sezonālītāti, jo šīs īpašības parasti ietekmē imputācijas metodes izvēli (Ribeiro & de Castro, 2022). Tas prasītu arī papildu zināšanas par uzņēmumam raksturīgajiem pārdošanas faktoriem, kas šajā pētījumā nav pieejamas.

Tātad, pat ja šī darba imputācija tika veikta (jeb primitīvāk sakot, mēnešu kopēšanai) paļautos tikai uz dotiem datiem, kokmateriālu literatūra joprojām liecina par pretējo – sezonālā dinamika pastāv joprojām ir ļoti specifiska tirgum un var mainīties laika gaitā (svārstīties). Plašākā nozīmē tas nozīmē, ka nav vienas universāli labākās prognozēšanas metodes katrai situācijai; vispiemērotākā metode ir atkarīga no datu sarežģītības un īpašībām (Zhang, 2003). Šo iemeslu dēļ imputācija šajā pētījumā netiek izmantota, tikai logu apvienošana.

6.2. Python implementācija

Papildināšanas eksperiments tika realizēts esošajā LSTM prognozēšanas skriptā. Sākotnējā LSTM implementācija vispirms ģenerēja slidošos logus no grupētajām laika rindām, pēc tam standartizēja iegūtos objektus, apmācīja vienu apkopotu modeli visās grupās un tad prognozēja nākamo mēnesi katrai materiālu grupai. Modificētā implementācija saglabā šo struktūru un maina tikai logu ģenerēšanas posmu – kad datu

sintētika ir iespējota (skriptā ir nodrošināts, lai būtu iespējams to ieslēgt/izslēgt), katrs jaunizveidotais reālais logs tiek apvienots ar iepriekšējo tās pašas materiālu grupas reālo logu. Sintētiskais logs un mērķis tiek konstruēti kā divu blakus esošo logu un mērķu aritmētiskais vidējais. Matemātiski, ja divi blakus logi ir apzīmēti kā (X_1, y_1) un (X_2, y_2) , tad sintētiskais logs ir $((X_1 + X_2)/2, (y_1 + y_2)/2)$. Vizuāli izmaiņas logu ģenerēšanas kodā ir redzamas zemāk.

```

def build_sample(groups_features_by_periods, train_start, train_end):
    x = []
    group_ids = []
    y = []

    for group_name, group_id, group_periods in groups_features_by_periods:
        train_periods_df = group_periods.loc[train_start:train_end]
        period_features_np = train_periods_df.to_numpy(dtype=np.float32)

        for i in range(len(period_features_np) - TIMESTEP_COUNT):
            x.append(period_features_np[i:i+TIMESTEP_COUNT])
            group_ids.append(group_id)
            y.append(train_periods_df["sale_m3"].iloc[i + TIMESTEP_COUNT])

    x = np.array(x, dtype=np.float32)
    group_ids = np.array(group_ids, dtype=np.int64)
    y = np.array(y, dtype=np.float32).reshape(-1, 1)

    return x, group_ids, y

def build_windows(groups_features_by_periods, train_start, train_end, augment_data=False):
    x = []
    group_ids = []
    y = []

    for group_name, group_id, group_periods in groups_features_by_periods:
        train_periods_df = group_periods.loc[train_start:train_end]
        period_features_np = train_periods_df.to_numpy(dtype=np.float32)

        previous_window = current_window = previous_target = current_target = None
        for i in range(len(period_features_np) - TIMESTEP_COUNT):
            previous_window = current_window
            previous_target = current_target
            current_window = period_features_np[i:i+TIMESTEP_COUNT]
            current_target = train_periods_df["sale_m3"].iloc[i + TIMESTEP_COUNT]

            if augment_data and previous_window is not None and previous_target is not None:
                synthetic_x = (previous_window + current_window) / 2.0
                synthetic_y = (previous_target + current_target) / 2.0

                x.append(synthetic_x)
                group_ids.append(group_id)
                y.append(synthetic_y)

            x.append(current_window)
            group_ids.append(group_id)
            y.append(current_target)

```

6.1. att. Izmaiņas, kas pievieno datu papildināšanu esošajai ieviešanai

Rezultāta piemēru var redzēt zemāk. Pilnu rezultātu var atrast 7. pielikumā.

6.1. tabula

LSTM ar papildinātiem datiem rezultāta piemērs

material_group	test_month	actual	prediction	abs_error	sq_error	ape
BUVNIEKS: NEĒVELĒTI	2026-01	2.411	6.603	4.191	17.568	1.738
BUVNIEKS: ĒVELĒTI	2026-01	0.878	4.473	3.596	12.931	4.098
...						
KARTEX: TERASES DĒĻI	2026-03	1.579	4.202	2.624	6.885	1.662
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.091	1.179	1.39	0.928

6.3. LSTM novērtēšana ar papildinātiem apmācības datiem

Šoreiz salīdzinājums tika veikts ar sākotnējo LSTM modeli, kas apmācīts ar reāliem datiem, un ar naivo metodi, jo tas ir galvenais bāzes modelis (OpenAI, 2026). Papildinātām LSTM apmācības laikā tika izmantoti papildinātie dati. Prognozes rezultāti ir parādīti 6.2. tabulā. Tika izmantoti tie paši novērtēšanas rādītāji kā 5.7. sadaļā. MAE un RMSE ir izteikti kubikmetros, savukārt MAPE, pielāgotie procentuālie rādītāji un WAPE ir izteikti procentos. Galīgais rangs ir balstīts uz WAPE

6.2. tabula

LSTM variāciju rezultātu salīdzinājums

Modelis	MAE, m ³	RMSE, m ³	MAPE, 13/21 gadījumiem, %	Pielāgots MAPE, %	Grupām pielāgots WAPE, %	WAPE, %
Naive	1.717	3.731	122.94	76.59	229.74	130.3%
LSTM	3.359	4.673	619.23	250.87	752.61	254.9
LSTM ar sintētiskiem datiem	3.328	4.856	959.70	205.03	615.09	252.60

Ar zaļo fonu ir atzīmētā metode ar labāko WAPE vērtību

Rezultāti liecina, ka papildinātais LSTM nedaudz uzlaboja dažus apkopotus rādītājus, salīdzinot ar sākotnējo LSTM. MAE samazinājās no 3.359 līdz 3.328, pielāgots MAPE samazinājās no 250.87% līdz 205.03%, grupām pielāgots WAPE samazinājās no 752.61% līdz 615.09% un WAPE samazinājās no 254.90% līdz 252.60%. Tomēr RMSE un MAPE palielinājās no 4.673 līdz 4.856 un no 619.23% līdz 959.70%, respektīvi.

RMSE parāda lielas kļūdas, MAE – vidējas absolūtās kļūdas, WAPE – kopējo absolūto kļūdu attiecībā pret faktiskām pārdošanas apjomiem. Šīs kļūdas mainījās dažādos virzienos, līdz ar to uzlabojums nav skaidri redzams. Šī iemesla dēļ bija izdomāts veikt papildu salīdzināšanu, pārbaudot atsevišķus gadījumus: katra prognoze tika salīdzināta starp sākotnējo LSTM un paplašināto LSTM. Gadījums tika uzskatīts par uzlabotu, ja paplašinātajam LSTM bija zemāka absolūtā kļūda (tā pati materiālu grupa un tas pats testa mēnesis). Rezultātus var redzēt 6.3. tabulā.

6.3. tabula

Absolūtās kļūdas izmaiņas starp LSTM modeļiem

Gadījums	Gadījumu skaits
Paplašinātajai LSTM metodei bija zemāka absolūtā kļūda nekā parastai LSTM	9
Paplašinātajai LSTM metodei bija lielāka absolūtā kļūda nekā parastai LSTM	11
Vienāda absolūtā kļūda	1

6.3. tabulā redzams, ka uzlabojums nav sistemātisks: papildināts modelis uzlaboja prognozes tikai 9 no 21 gadījuma, bet pasliktināja 11. Tas nozīmē, ka nedaudz labākās MAE un WAPE vērtības nenorāda uz labāku modeli, bet uz kādu citu faktoru. Lai to pierādītu, testa gadījumi tika sadalīti trīs grupās, kuras pēc tam tika analizētas individuāli. Grupas pārstāv:

- gadījumus ar nulles faktisko pārdošanas apjomu,
- gadījumus ar mazāku par nenulles faktisko pārdošanas apjomu mediānu,
- gadījumus ar lielāku vai vienādu ar nenulles faktisko pārdošanas apjomu mediānu.


Mediāna izrādījās 1.270 m³. Rezultātu analīzei var ieraudzīt 6.4. tabulā. Apjoma grupas var arī vizuāli ieraudzīt 6.2. attēlā.

6.4. tabula

Metrikas izmaiņas dažādiem pārdošanas grupām LSTM prognozēs

Apjoma grupa	Gadījumi	LSTM MAE, m ³	Paplašinātā LSTM MAE, m ³	LSTM WAPE, %	Paplašinātā LSTM WAPE, %	Palīdzēja / pasliktināja / neizmainījās
Nulle faktiskas pārdošanas	8	3.420	1.851	-	-	5 / 3 / 0
Zemas nenulles pārdošanas	6	1.545	2.125	356.95	490.99	2 / 4 / 0
Augstas nenulles pārdošanas	7	4.845	6.048	135.23	168.82	2 / 4 / 1

WAPE netika aprēķināts nulles pārdošanas apjoma grupai, jo dalītāja (faktisko pārdošanu summa) būtu nulle



6.2. att. Testa mēnešu faktisko pārdošanas apjoma grupas

Tabula rāda, ka papildinātais LSTM galvenokārt uzlaboja prognozes nulles pārdošanas gadījumiem. Šajā grupā MAE samazinājās no 3.420 līdz 1.851, un papildinātais modelis uzlaboja 5 no 8 gadījumiem. Tomēr abās nenulles grupās papildināts rezultāts pasliktinājās: maza apjoma nenulles gadījumos WAPE palielinājās no 356.95% līdz 490.99%; liela apjoma - no 135.23% līdz 168.82%. Šis rezultāts izskaidro nelielo kopējo WAPE uzlabojumu – nulles pārdošanas gadījumu kopējā kļūda samazinājās, samazinot kopējo absolūto kļūdu, bet uzlabojumu gandrīz pilnībā kompensēja sliktākas nenulles faktiskās pārdošanas prognozes gadījumos. Tātad, nulles pārdošanas gadījumi palielina WAPE formulas skaitītāju absolūtās kļūdas dēļ, saucējs paliek nemainīgs (faktisko vērtību summa), formula ģenerē mazāku skaitli, kas praktiski norāda uz kļūdaini pozitīvu prognožu samazināšanos un kopējā WAPE samazināšanos. Taču patiesībā tas nozīmē, ka modelis nekļuva labāks prognozēšanā, tas uzlaboja tikai nulles pārdošanas gadījumu prognozēšanu.

Šāds rezultāts, iespējams, ir saistīts ar to, ka sintētiskie dati palielināja apmācības laika rindu skaitu, bet neparādīja nekādu jaunu informāciju par pieprasījuma uzvedību vai likumsakarībām. Ar šī darba īsu datu kopu šāda papildināšana izlīdzina lokālās svārstības, bet tā neuzlabos modeli. Semenoglou, Spiliotis un Assimakopoulos (2023) uzsvēra, ka papildināšanas veikspēja ir atkarīga no izmantotās metodes un ka dažas metodes var pat nodrošināt negatīvus uzlabojumus. Viņi arī secina, ka efektīvai papildināšanai ir nepieciešams pareizi saglabāt līdzību ar sākotnējo sēriju. Wen (2021)

līdzīgi runā par nepieciešamību saglabāt reālu datu īpašības, izmantojot datu papildināšanas metodes.

Ir vērts arī pievērst uzmanību pārdošanas apjoma sadalījumam 6.4. tabulā. Lielu daļu no gadījumiem pārstāv mēneši ar nulles un zemu pārdošanas apjomu. Prognozēšanas literatūrā šādus gadījumus (periodisks pieprasījums) bieži prognozē ar Croston tipa metodēm, SBA vai TSB (Filali, et al., 2022; Croston, 1972). Šoreiz šīs metodes netiek ieviestas, taču autors iesaka pievērst tiem uzmanību turpmākajā darbā.

Kopumā eksperiments nesniedz pietiekamus pierādījumus tam, ka datu papildināšanas metode uzlaboja LSTM modeli, uzlabojums ir neliels. Gadījumu līmeņa analīze parādīja, ka papildinātais modelis sniedza sliktākas prognozes vairākos gadījumos nekā tajos, kuros prognoze uzlabojās (salīdzinājumā ar vienkāršo LSTM). Apjoma analīze parādīja, ka galvenokārt uzlabojās nulles pārdošanas gadījumi. Tomēr abi LSTM varianti joprojām bija sliktāki nekā naivā bāzes metode. Līdz ar to šīs nodaļas starpsecinājums ir tas, ka sintētisko datu papildināšana tika ieviesta un novērtēta, taču tās praktiskais ieguvums šajā darbā netika apstiprināts.

REZULTĀTI UN SECINĀJUMI

Rezultāti un secinājumi ir izdarīti no literatūras apskata, darba ar uzņēmumu datiem, praktiskās daļas un rezultātu novērtējumiem.

1. ETL jeb datu parsēšanas algoritms tika izstrādāts, lai iegūtu, normalizētu un sagatavotu uzņēmuma datu kopu (sākotnēji glabātu kā Excel fails), lai to vēlāk izmantotu laika rindu modeļu apmācībā. Skripts nolasa mēneša Excel lapas, atrod materiālu ierakstus, normalizē ierakstus, izvelk pārdošanas, piegāžu un citus ierakstus un ielādē tos SQLite datubāzē. Datubāzē tiek glabāta atsevišķu materiālu, pārdošanas, piegāžu un mēneša beigu statistika.
2. Datu analīzes laikā tika konstatēts, ka pieejamie dati aptver īsu periodu, tomēr ir pietiekami lai tos izmantotu prognozēšanas metodēs un salīdzinātu savā starpā, taču rezultātu interpretēšanā un secinājumi būtu jāizdara uzmanīgi. Lai gan tika sagaidīts, ka šis ierobežojums ietekmēs rezultātus un sarežģīs visu eksperimentu, tas lika autoram meklēt veidus, kā papildināt datus kā rīku apmācības datu kopas paplašināšanai un tādējādi modeļa prognozēšanas spēju uzlabošanai.
3. Izmantojot literatūru un autora zināšanas, tika noteikts, ka pašreizējais datu kopums ir laikrindu tipa. Tas noveda pie iepazīšanās ar tradicionālajām laikrindu prognozēšanas metodēm (eksponenciālā izlīdzināšana, ARIMA saime, Holt-Winters, SMA, WMA) un neironu tīkliem (LSTM), no kurām pēc datu analīzes tika izvēlēta galīgā metožu kopa.
4. Naivā bāzes modelis (prognozē, ka pārdošanas apjomi būs tādi paši kā pēdējā iedotā mēnesī) sasniedza vislabāko kopējo rezultātu saskaņā ar WAPE, padarot to efektīvāku par sarežģītākām metodēm pašreizējam datu kopumam. Tāpēc prognozēšanas eksperimentos ir svarīgi iekļaut vienkāršas bāzes modeles – tas parāda, vai modelis vispār sniedz labu rezultātu.
5. Vienkāršais eksponenciālās izlīdzināšanas modelis neuzrādīja labākus rezultātus nekā naivā bāzes modelis. Metode ir vienkārša un plaši izmantota, taču šajā eksperimentā tā nespēja iegūt pietiekami daudz noderīgu datu un darboties labi. Rezultāts liecina, ka jaunākā faktiskā

vērtība (naivā pieeja) ir vienkārši informatīvāka par izlīdzināto vēsturisko vidējo vērtību.

6. Arī ARIMA modelis neuzrādīja labākus rezultātus nekā naivā bāzes modelis un SES. Šajā darbā tika salīdzinātas dažādas ARIMA konfigurācijas, un, izmantojot AIC, tika izvēlēta labākā, taču pat tad modelis nespēja iegūt pietiekami daudz informācijas no pieejamajiem datiem.
7. Arī LSTM modelis neuzrādīja labākus rezultātus nekā naivā bāzes metode vai tradicionālās metodes, lai gan tam tika nodrošināts vairāk ievades pazīmju nekā citām metodēm – piegādes, atšķirības starp periodiem, slīdošie vidējie rādītāji un materiālu grupu iegulšana. Tas nozīmē, ka papildu ievades dati (manuāli iegūti no datiem) kombinācijā ar neironu tīkla pieeju nebija pietiekami, lai kompensētu datu ierobežotību. Negatīvais LSTM rezultāts joprojām ir nozīmīgs darba rezultāts, jo tas parāda, ka sarežģītāka modeļa izvēle pati par sevi negarantē labāku prognozēšanas kvalitāti, pat ja uz to norāda citi pētījumi.
8. Sintētisko datu papildināšana deva dažādus rezultātus. Tika pārskatītas vairākas iespējamās papildināšanas metodes, taču tikai viena tika uzskatīta par iespējamu izmantot ar ierobežoto šajā darbā pieejamo datu kopu: papildu apmācības laika rindu izveide, aprēķinot blakus esošo apmācības paraugu vidējo vērtību. Tas paplašināja pieejamo datu kopu (gandrīz divreiz lielāku par sākotnējo izmēru), lai uz tās varētu apmācīt citu LSTM, lai redzētu, vai tas sniegs labākus rezultātus. Daži rādītāji uzlabojās, bet daži pasliktinājās, salīdzinot ar sākotnējo LSTM. Tātad secinājums ir šāds: izvēlēta datu papildināšanas metode neuzlaboja LSTM spēju prognozēt pašreizējā kontekstā.
9. Vēl viens praktiski atkārtoti izmantojams darba rezultāts ir izstrādātā datu apstrādes un prognozēšanas plūsma (pipeline). Tā ietver ETL skripta pielietošanu, materiālu grupu izveidi, apmācības un testa kopu sagatavošanu, modeļu apmācību, prognožu ģenerēšanu un rezultātu izvērtēšanu. Kad būs pieejami jauni dati, šo procesu būs iespējams atkārtoti palaist un salīdzināt jaunus rezultātus ar šajā darbā iegūtajiem. Šī atkārtotā izmantošana ir iespējama, ja uzņēmums būtiski nemaina

pārdošanas datu dokumentēšanas struktūru, pretējā gadījumā ETL skriptu būs nepieciešams pielāgot.

Turpmākie pētījuma virzieni ir saistīti ar diviem aspektiem: datu kopas pieaugums ar laiku un izstrādātās datu apstrādes plūsmas pilnveidošanu.

1. Pašlaik ir grūti novērtēt sezonālītāti un citas ārējās ietekmes. Kad tiek apkopots vairāk datu (vismaz pilna gada ciklā), to pašu skriptu plūsmu var atkārtoti izmantot, lai sasniegtu, iespējams, labākus rezultātus un salīdzinātu tos ar šajā darbā iegūtajiem.
2. Prognozēšanas mērķim vajadzētu mainīties no materiālu grupām uz atsevišķiem materiāliem. Šajā darbā materiālu grupēšana ir nepieciešama pieeja neliela datu kopuma dēļ. Ar lielāku vēsturisko datu apjomu vajadzētu kļūt iespējamai atsevišķu materiālu prognozēšanai.
3. Literatūras apskatā apskatītās, bet šajā darbā neizmantotās metodes varētu tikt atkārtoti izvērtētas, kad būs pieejams lielāks datu apjoms. SARIMA, ARIMAX un SARIMAX modeļi labāk atpazīst sezonālītātes un ārējus mainīgus (piegādes, krājumu līmeni, cenas, atlaides, dati par klientu, pašreizējs tirgus stāvoklis utt.), savukārt Croston tipa pieejas, SBA un TSB varētu būt piemērotas neregulāra pieprasījuma un nulles pārdošanas periodu gadījumos (par ko bija runāts datu papildināšanas ar sintētiskajiem datiem sadaļā).
4. Ir vērts notestēt LSTM ar vairāk un slēptiem neironiem, ja pieejamie dati kļūst daudzveidīgāki.
5. Kad datu kopā ir vairāk mēnešu, varētu būt vairāk *train/test* sadalījumu (pašlaik trīs). Tas padarītu novērtējumu stabilāku. Ir iespējami arī ilgāki slīdošo pārdošanas logi (pašlaik divi un trīs mēneši).
6. Noderīga būtu arī vienkārša grafiskā lietotāja saskarne. Tai vajadzētu ļaut uzņēmumam palaist un konfigurēt visu plūsmu. Izstrādātā plūsma pašlaik tiek palaista manuāli, skriptu aiz skriptam. GUI būtu vienkārši vieglāk lietojams.

Ar bakalaura darba tēmu saistītas publikācijas, uzstāšanās konferencēs vai dalība zinātniski pētnieciskos projektos darba izstrādes laikā netika veikta.

IZMANTOTIE INFORMĀCIJAS AVOTI

- Abbasimehr, H., Abri, A., Oskouei, A. G., & Noshad, A. (2025). Multi-view clustering for localized global time series forecasting. *Neurocomputing*, 653. doi:10.1016/j.neucom.2025.131183
- Aichner, T., & Santa, V. (2023). Demand Forecasting Methods and the Potential of Machine Learning in the FMCG Retail Industry. *Serving the Customer*. doi:10.1007/978-3-658-39072-3_8
- Ali, Y., & Nakti, S. (2023). Sales Forecasting: A Comparison of Traditional and Modern Times-Series Forecasting Models on Sales Data with Seasonality., (lpp. 159-163). New Delhi, India. Ielādēts no <https://ieeexplore.ieee.org/document/10112431>
- ArunKumar, K., Kalaga, D. V., Kumar, C. M., Chilkoor, G., Kawaji, M., & Brenza, T. M. (2021). Forecasting the dynamics of cumulative COVID-19 cases (confirmed, recovered and deaths) for top-16 countries using statistical machine learning models. *Applied Soft Computing*, 103. doi:10.1016/j.asoc.2021.107161
- Bandara, K., Bergmeir, C., & Smyl, S. (2020). Forecasting across time series databases using recurrent neural networks on groups of similar series: A clustering approach. *Expert Systems With Applications*, 140. doi:10.1016/j.eswa.2019.112896
- Bender, B., Bretschneider, S., & Fattah-Weil, J. (2024). Advances in Demand Forecasting: A Systematic Review of Methods, The Role of AI, and Data Strategies in Manufacturing. *30th Americas Conference on Information Systems, AMCIS 2024*. Salt Lake City: Association for Information Systems.
- Borrouhou, S., Fissoune, R., & Badir, H. (2025). The role of data transformation in modern analytics: A comprehensive survey. *Journal of Computer Languages*, 10.1016/j.cola.2025.101329.
- Chiang, C.-C., & Fu, H.-C. (1992). A Variant of Second-Order Multilayer Perceptron and Its Application to Function Approximations. *Proceedings of the IEEE Conference* (lpp. III-887–III-892). IEEE. doi:10.1109/IJCNN.1992.227087
- Croston, J. D. (1972). Forecasting and Stock Control for Intermittent Demands. *Operational Research Quarterly*, 23(3), 289–303. doi:10.1057/jors.1972.50

- Demir, S., Mincev, K., Kok, K., & Paterakis, N. G. (2021). Data augmentation for time series regression: Applying transformations, autoencoders and adversarial networks to electricity price forecasting. *Applied Energy*, 304. doi:10.1016/j.apenergy.2021.117695
- Deniss, G. (2026). *denissgrabovskis/bachelor*. Ielādēts no GitHub: <https://github.com/denissgrabovskis/bachelor/commit/ccb99f59424d3ee36229f7b2436874f618010f9d>
- Dick, G., Owen, C., & Whigham, P. A. (2020). Feature Standardisation and Coefficient Optimisation for Effective Symbolic Regression. *Genetic and Evolutionary Computation Conference*, 306–314. doi:10.1145/3377930.3390237
- Eglite, L., & Birzniece, I. (2022). Retail Sales Forecasting Using Deep Learning: Systematic Literature Review. *Complex Systems Informatics and Modeling Quarterly*, 30, 53-62. doi:10.7250/csimq.2022-30.03
- Elmotawakkil, A., Enneya, N., Bhagat, S. K., Ouda, M. M., & Kumar, V. (2025). Advanced machine learning models for robust prediction of water quality index and classification. *Journal of Hydroinformatics*, 27(2). doi:0.2166/hydro.2025.290
- Emerson, M., & Napoleao, V. (2022). Retail sales forecasting information systems: comparison between traditional methods and machine learning algorithms. *IADIS International Conference Information Systems* (lpp. 30-38). Internations Association for Development of the Information Society. Ielādēts no <https://www.iadisportal.org/digital-library/retail-sales-forecasting-information-systems-comparison-between-traditional-methods-and-machine-learning-algorithms>
- Filali, A., Benlahmar, E., Filali, S., Kasbouya, M., Ajouary, M., & Akantous, S. (2022). Machine Learning Applications in Supply Chain Management: A Deep Learning Model Using an Optimized LSTM Network for Demand Forecasting. *International Journal of Intelligent Engineering and Systems*, 15, 464-478. doi:10.22266/ijies2022.0430.42
- Forbes, K. F. (2021). A Methodology to Improve the Predictability of Wind Energy Generation with Confirmatory Evidence from Germany. *20th International Workshop on Large-Scale Integration of Wind Power into Power Systems as well as on Transmission Networks for Offshore Wind Power Plants (WIW 2021)* (lpp. 104-109). IEEE. doi:10.1049/icp.2021.2606

- Hu, J., Hu, Z., Li, T., & Du, S. (2023). A contrastive learning based universal representation for time series forecasting. 86-98. doi:10.1016/j.ins.2023.03.143
- Iglesias, G., Talavera, E., González-Prieto, Á., Mozo, A., & Gómez-Canaval, S. (2023). Data Augmentation techniques in time series domain: a survey and taxonomy. *Neural Computing and Applications*, 35, 10123–10145. doi:10.1007/s00521-023-08459-3
- Ji, C. (2024). A Survey of Neural Network Optimization Algorithms. *2024 IEEE 4th International Conference on Data Science and Computer Application (ICDSCA)* (lpp. 409–415). IEEE. doi:10.1109/ICDSCA63855.2024.10859435
- Makridakis, S., Spiliotis, E., & Vassilios Assimakopoulos. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. doi:10.1016/j.ijforecast.2021.11.013
- Minnett, R., Smith, A., Lennon, W., & Hecht-Nielsen, R. (2011). Neural network tomography: Network replication from output surface geometry. *Neural Networks*, 24, 484–492. doi:10.1016/j.neunet.2011.01.006
- Odukoya, O., Nwaneri, S., Odeniyi, I., Akodu, B., Oluwole, E., Olorunfemi, G., . . . Osuntoki, A. (2022). Development and Comparison of Three Data Models for Predicting Diabetes Mellitus Using Risk Factors in a Nigerian Population. *Health Inform Research*, 58-67. doi:10.4258/hir.2022.28.1.58
- OpenAI. (2026. gada aprīlis). *ChatGPT atbilde uz uzvedni: "Analyze LSTM and augmented LSTM forecasting results and compare model errors by sales-volume groups"*. Ielādēts no ChatGPT: <https://chatgpt.com/>
- OpenAI. (2026. gada marts). *ChatGPT atbilde uz uzvedni: "Help implement an LSTM model for monthly timber sales forecasting using Python/PyTorch"*. Ielādēts no ChatGPT: <https://chatgpt.com/>
- OpenAI. (2026. gada aprīlis). *ChatGPT atbilde uz uzvedni: "Identify data augmentation practices for limited time-series forecasting data"*. Ielādēts no ChatGPT: <https://chatgpt.com/>
- Pongdatu, G., & Putra, Y. (2018). Seasonal Time Series Forecasting using SARIMA and Holt Winter's Exponential Smoothing. doi:10.1088/1757-899X/407/1/012153
- Pulla, S., Yasarer, H., & Yarbrough, L. (2024). Synthetic Time Series Data in Groundwater Analytics: Challenges, Insights, and Applications. *Water*, 16(7), 949. doi:10.3390/w16070949

- Rajesh, R. D., Kuppuri, Y. N., Peter, P. R., Reddy, A. S., & Sonia, D. J. (2025). Enhancing Obesity Prediction: Evaluating the Role of Data Preprocessing in Machine Learning Models. *International Conference on Computational Robotics, Testing and Engineering Evaluation*. doi:10.1109/ICCRTEE64519.2025.11053002
- Ramchoun, H., Idrissi, M., Ghanou, Y., & Ettaouil, M. (2019). Multilayer Perceptron: Architecture Optimization and Training. *International Journal of Interactive Multimedia and Artificial Intelligence*, 5(1), 26–30. doi:10.9781/ijimai.2019.02.002
- Ribeiro, S. M., & de Castro, C. L. (2022). Missing Data in Time Series: A Review of Imputation Methods and Case Study. *Learning and Nonlinear Models*, 20(1), 31–46. doi:10.21528/lnlm-vol20-no1-art3
- Rosenblad, A. (2021). Accuracy of automatic forecasting methods for univariate time series data: A case study predicting the results of the 2018 Swedish general election using decades-long data series. *Communications in Statistics: Case Studies, Data Analysis and Applications*, 7(3), 475-493. doi:10.1080/23737484.2021.1964407
- Santis, F. D., Giordano, D., & Mellia, M. (2026). GLEm-Net: Unified framework for data reduction with categorical and numerical features. *Knowledge-Based Systems*, 334. doi:10.1016/j.knosys.2025.115049
- Semenoglou, A.-A., Spiliotis, E., & Assimakopoulos, V. (2023). Data augmentation for univariate time series forecasting with neural networks. *Pattern Recognition*, 134. doi:10.1016/j.patcog.2022.109132
- Sirisha, U., Belavagi, M., & Attigeri, G. (2022). Profit Prediction Using ARIMA, SARIMA and LSTM Models in Time Series Forecasting: A Comparison. *IEEE Access*, 10, 124715-124727. doi:10.1109/ACCESS.2022.3224938
- statsmodels developers. (bez datuma). *statsmodels.tsa.statespace.sarimax.SARIMAX*. Ielādēts 2026. gada 15. 04 no <https://www.statsmodels.org:https://www.statsmodels.org/dev/generated/statsmodels.tsa.statespace.sarimax.SARIMAX.html#statsmodels.tsa.statespace.sarimax.SARIMAX>
- Suresh, B., & Suresh, M. (2023). A Comprehensive Analysis of Retail Sales Forecasting Using Machine Learning and Deep Learning Methods., (lpp. 1-5). Tiptur, India. doi:10.1109/ICDSNS58469.2023.10245887

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., . . . Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998-6008. doi:10.48550/arXiv.1706.03762
- Wen, Q., Sun, L., Yang, F., Song, X., Gao, J., Wang, X., & Xu, H. (2021). Time Series Data Augmentation for Deep Learning: A Survey. *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence*, (lpp. 4653-4660). Hangzhou. doi:10.24963/ijcai.2021/631
- Yunita, A., Pratama, M., Almuzakki, M., Ramadhan, H., Akhir, E., Mansur, A., & Basori, A. (2025). Performance analysis of neural network architectures for time series forecasting: A comparative study of RNN, LSTM, GRU, and hybrid models. doi:10.1016/j.mex.2025.103462
- Zhang, G. P. (2003). Time Series Forecasting Using a Hybrid ARIMA and Neural Network Model. *Neurocomputing*, 50, 159-175. doi:10.1016/S0925-2312(01)00702-0

PIELIKUMI

1. pielikums

Uzņēmuma Excel dati

2025 Noliktava Kartex Wood.xlsx - Excel																									
File Home Insert Page Layout Formulas Data Review View Developer Help Tell me what you want to do																									
Clipboard Font Alignment Number Styles Cells Editing Add-ins																									
ES 6																									
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y
		KVALITĀTE	AUGSTUMS (m)	PLATUMS (m)	GARUMS (m)	m3 (tgb)	m2 (tgb)	IEPIRKUMA CENA	Cena m3	Cena 1 gb	Cena m2	DAUDZUMS (gb.)	Kopi m3	Kopa m2	PĀRDOTS (gb.)	PĀRDOTS (m3)	PĀRDOTS (tgb.)	SAĒMAM (gb.)	SAĒMAM (m3)	ATLIKUMS (gb.)	ATLIKUMS (m3)	ATLIKUMS (m2)	ATLIKUMS (t)		
1																									
2		TERASES DĒLI																							
3			0.027	0.140	4.80	0.0181	0.6720		626.78	11.37	16.92	226	4.10	151.87		0.0000	0.00		0.00	226	4.10	151.87	2570.14		
4		Impregnēta	0.028	0.120	4.50	0.0151	0.5400		544.50	8.23	15.25	51	0.77	27.54	3	0.0454	66.41		0.00	48	0.73	25.92	395.18		
5			0.028	0.145	6.00	0.0244	0.8700		544.50	13.26	15.25	75	1.83	65.25	3	0.0731	39.79		0.00	72	1.75	62.64	955.01		
6			0.045	0.145	6.00	0.0392	0.8700		544.50	21.32	24.50	28	1.10	24.36		0.0000	0.00		0.00	28	1.10	24.36	596.88		
7			0.027	0.140	4.20	0.0159	0.5880		626.78	9.95	16.92	217	3.45	127.60		0.0000	0.00		0.00	217	3.45	127.60	2159.31		
8		BC	0.030	0.145	3.00	0.0131	0.4350		423.50	5.53	12.71	126	1.64	54.81		0.0000	0.00		0.00	126	1.64	54.81	696.36		
9		BC	0.030	0.120	4.80	0.0173	0.5760		423.50	7.32	12.71	62	1.07	35.71		0.0000	0.00		0.00	62	1.07	35.71	453.72		
10		ABC	0.030	0.100	3.00	0.0090	0.3000		484.00	4.36	14.52	184	1.66	55.20		0.0000	0.00		0.00	184	1.66	55.20	801.50		
11		BC	0.030	0.140	3.60	0.0151	0.5040		423.50	6.40	12.71	147	2.22	74.09		0.0000	0.00		0.00	147	2.22	74.09	941.29		
12		BC	0.030	0.145	4.80	0.0209	0.6960		423.50	8.84	12.71	221	4.61	153.82		0.0000	0.00		0.00	221	4.61	153.82	1954.23		
13		BC	0.028	0.145	3.60	0.0146	0.5220		423.50	6.19	11.86	40	0.58	20.88		0.0000	0.00		0.00	40	0.58	20.88	247.60		
14		BC	0.028	0.145	6.00	0.0244	0.8700		423.50	10.32	11.86	72	1.75	62.64		0.0000	0.00		0.00	72	1.75	62.64	742.79		
15		BC	0.030	0.100	6.00	0.0180	0.6000		423.50	7.62	12.71	45	0.81	27.00		0.0000	0.00		0.00	45	0.81	27.00	343.04		
16		BC	0.030	0.145	3.60	0.0157	0.5220		423.50	6.63	12.71	97	1.52	50.63		0.0000	0.00		0.00	97	1.52	50.63	643.30		
17		BC	0.045	0.145	6.00	0.0392	0.8700		423.50	16.58	19.06	138	5.40	120.06		0.0000	0.00		0.00	138	5.40	120.06	2288.04		
18		BC	0.030	0.120	3.60	0.0130	0.4320		423.50	5.49	12.71	162	2.10	69.98		0.0000	0.00		0.00	162	2.10	69.98	889.15		
19		Sibīrijas lapegle	0.028	0.145	2.40	0.0097	0.3480		1052.70	10.26	29.48	1068	10.41	371.66		0.0000	0.00		0.00	1068	10.41	371.66	10955.02		
20		BC	0.045	0.195	6.00	0.0527	1.1700		423.50	22.30	19.06	11	0.58	12.87		0.0000	0.00		0.00	11	0.58	12.87	245.27		
21			0.030	0.145	4.80	0.0209	0.6960		605.00	12.63	18.15	84	1.75	58.46		0.0000	0.00		0.00	84	1.75	58.46	1061.12		
22			0.028	0.120	4.80	0.0161	0.5760		561.44	9.05	15.72	54	0.87	31.10		0.0000	0.00		0.00	54	0.87	31.10	488.96		
23			0.030	0.145	5.10	0.0222	0.7395		568.70	12.62	17.06	229	5.08	169.35	1	0.0222	6.59		0.00	228	5.06	168.61	2876.59		
24			0.028	0.115	3.00	0.0097	0.3450		544.50	5.26	15.25	72	0.70	24.84		0.0000	0.00		0.00	72	0.70	24.84	378.71		
25			0.030	0.145	3.60	0.0157	0.5220		548.13	8.58	16.44	12	0.19	6.26		0.0000	0.00		0.00	12	0.19	6.26	103.00		
26			0.028	0.095	3.00	0.0080	0.2850		544.50	4.35	15.25	600	4.79	171.00		0.0000	0.00		0.00	600	4.79	171.00	2607.07		
27			0.045	0.120	3.00	0.0162	0.3600		544.50	8.82	24.50	805	13.04	289.80		0.0000	0.00		0.00	805	13.04	289.80	7100.82		
28		Sibīrijas lapegle	0.028	0.145	3.00	0.0122	0.4350		1052.70	12.82	29.48	766	9.33	333.21		0.0000	0.00		0.00	766	9.33	333.21	9821.56		
29		KOPA							519.96	9.85	16.75		81.35	2590.00		0.14	112.79				81.21		52315.67		
30		APDARES DĒLI																							
31			0.010	0.146	4.80	0.0133	0.7008		602.58	8.02	11.45	216	2.88	151.37		0.0000	0.00		0.00	216	2.88	151.37	1733.07		

2. pielikums

Pārdošanas apjoma tabula pēc mēneša un materiālu grupas

	Zīmols: kategorija	Mēnesis	Pārdošanas apjoms <i>sale</i> m3
1	BUVNIEKS: NEĒVELĒTI	2025-07	0
2	BUVNIEKS: NEĒVELĒTI	2025-08	20.762
3	BUVNIEKS: NEĒVELĒTI	2025-09	36.76175
4	BUVNIEKS: NEĒVELĒTI	2025-10	14.9934
5	BUVNIEKS: NEĒVELĒTI	2025-11	33.86992
6	BUVNIEKS: NEĒVELĒTI	2025-12	16.86265
7	BUVNIEKS: NEĒVELĒTI	2026-01	2.41118
8	BUVNIEKS: NEĒVELĒTI	2026-02	4.1656
9	BUVNIEKS: NEĒVELĒTI	2026-03	12.333075
10	BUVNIEKS: ĒVELĒTI	2025-07	0
11	BUVNIEKS: ĒVELĒTI	2025-08	0.0997272
12	BUVNIEKS: ĒVELĒTI	2025-09	0.1827
13	BUVNIEKS: ĒVELĒTI	2025-10	8.7014844
14	BUVNIEKS: ĒVELĒTI	2025-11	1.3068
15	BUVNIEKS: ĒVELĒTI	2025-12	0.0594
16	BUVNIEKS: ĒVELĒTI	2026-01	0.8775
17	BUVNIEKS: ĒVELĒTI	2026-02	0
18	BUVNIEKS: ĒVELĒTI	2026-03	0.09198
19	KARTEX: APDARES DĒĻI	2025-07	2.6610684
20	KARTEX: APDARES DĒĻI	2025-08	3.9957768
21	KARTEX: APDARES DĒĻI	2025-09	1.6714116
22	KARTEX: APDARES DĒĻI	2025-10	6.9437835
23	KARTEX: APDARES DĒĻI	2025-11	2.7061335
24	KARTEX: APDARES DĒĻI	2025-12	0.9467136
25	KARTEX: APDARES DĒĻI	2026-01	1.952634
26	KARTEX: APDARES DĒĻI	2026-02	0
27	KARTEX: APDARES DĒĻI	2026-03	1.365354
28	KARTEX: DAŽĀDAS PRECES	2025-07	0.0
29	KARTEX: DAŽĀDAS PRECES	2025-08	0
30	KARTEX: DAŽĀDAS PRECES	2025-09	0
31	KARTEX: DAŽĀDAS PRECES	2025-10	0
32	KARTEX: DAŽĀDAS PRECES	2025-11	0
33	KARTEX: DAŽĀDAS PRECES	2025-12	0
34	KARTEX: DAŽĀDAS PRECES	2026-01	0
35	KARTEX: DAŽĀDAS PRECES	2026-02	0
36	KARTEX: DAŽĀDAS PRECES	2026-03	0
37	KARTEX: GRĪDAS DĒĻI	2025-07	0
38	KARTEX: GRĪDAS DĒĻI	2025-08	0
39	KARTEX: GRĪDAS DĒĻI	2025-09	0.2394
40	KARTEX: GRĪDAS DĒĻI	2025-10	0.1596
41	KARTEX: GRĪDAS DĒĻI	2025-11	0.01596
42	KARTEX: GRĪDAS DĒĻI	2025-12	0.4536
43	KARTEX: GRĪDAS DĒĻI	2026-01	0
44	KARTEX: GRĪDAS DĒĻI	2026-02	0
45	KARTEX: GRĪDAS DĒĻI	2026-03	0
46	KARTEX: KARKASS	2025-07	0.01215
47	KARTEX: KARKASS	2025-08	0.16905
48	KARTEX: KARKASS	2025-09	0.243

	Zīmols: kategorija	Mēnesis	Pārdošanas apjoms <i>sale_m3</i>
49	KARTEX: KARKASS	2025-10	0
50	KARTEX: KARKASS	2025-11	0.0972
51	KARTEX: KARKASS	2025-12	0.25515
52	KARTEX: KARKASS	2026-01	0
53	KARTEX: KARKASS	2026-02	0.486
54	KARTEX: KARKASS	2026-03	0.9747
55	KARTEX: KOKMATERIĀLI	2025-07	0.249912
56	KARTEX: KOKMATERIĀLI	2025-08	0.746712
57	KARTEX: KOKMATERIĀLI	2025-09	0.5792715
58	KARTEX: KOKMATERIĀLI	2025-10	2.61244125
59	KARTEX: KOKMATERIĀLI	2025-11	4.79379375
60	KARTEX: KOKMATERIĀLI	2025-12	0.837225
61	KARTEX: KOKMATERIĀLI	2026-01	0
62	KARTEX: KOKMATERIĀLI	2026-02	0
63	KARTEX: KOKMATERIĀLI	2026-03	0.11163
64	KARTEX: LĪSTE	2025-07	0
65	KARTEX: LĪSTE	2025-08	0
66	KARTEX: LĪSTE	2025-09	0
67	KARTEX: LĪSTE	2025-10	0
68	KARTEX: LĪSTE	2025-11	0
69	KARTEX: LĪSTE	2025-12	0
70	KARTEX: LĪSTE	2026-01	0
71	KARTEX: LĪSTE	2026-02	0
72	KARTEX: LĪSTE	2026-03	0
73	KARTEX: PIRTS	2025-07	0
74	KARTEX: PIRTS	2025-08	0.026505
75	KARTEX: PIRTS	2025-09	0.1809
76	KARTEX: PIRTS	2025-10	0
77	KARTEX: PIRTS	2025-11	0
78	KARTEX: PIRTS	2025-12	0
79	KARTEX: PIRTS	2026-01	0
80	KARTEX: PIRTS	2026-02	0
81	KARTEX: PIRTS	2026-03	0
82	KARTEX: TERASES DĒĻI	2025-07	0.140625
83	KARTEX: TERASES DĒĻI	2025-08	4.48455
84	KARTEX: TERASES DĒĻI	2025-09	1.3839
85	KARTEX: TERASES DĒĻI	2025-10	2.223648
86	KARTEX: TERASES DĒĻI	2025-11	0.9708
87	KARTEX: TERASES DĒĻI	2025-12	0.54432
88	KARTEX: TERASES DĒĻI	2026-01	0
89	KARTEX: TERASES DĒĻI	2026-02	0
90	KARTEX: TERASES DĒĻI	2026-03	1.578552
91	KARTEX: ŽOGA DĒĻI	2025-07	0
92	KARTEX: ŽOGA DĒĻI	2025-08	0.1872
93	KARTEX: ŽOGA DĒĻI	2025-09	0.2322
94	KARTEX: ŽOGA DĒĻI	2025-10	0.0828
95	KARTEX: ŽOGA DĒĻI	2025-11	0.108
96	KARTEX: ŽOGA DĒĻI	2025-12	0
97	KARTEX: ŽOGA DĒĻI	2026-01	0
98	KARTEX: ŽOGA DĒĻI	2026-02	0.054
99	KARTEX: ŽOGA DĒĻI	2026-03	1.27008
100	RONDI: C24	2025-07	0

	Zīmols: kategorija	Mēnesis	Pārdošanas apjoms <i>sale_m3</i>
101	RONDI: C24	2025-08	0
102	RONDI: C24	2025-09	0
103	RONDI: C24	2025-10	6.8445
104	RONDI: C24	2025-11	0.36855
105	RONDI: C24	2025-12	3.3696
106	RONDI: C24	2026-01	0
107	RONDI: C24	2026-02	0
108	RONDI: C24	2026-03	12.33225

3. pielikums

Naivā metodes rezultāts

material_group	test_month	actual, m3	prediction, m3	abs_error, m3	sq_error, m3	ape, %	custom_ape, %	group_wape, %	wape, %
BUVNIKS: NEĒVELĒTI	2026-01	2.411	16.863	14.451	208.845	599.40	76.40	128.90	130.30
BUVNIKS: ĒVELĒTI	2026-01	0.878	0.059	0.818	0.669	93.20	84.40	184.40	130.30
KARTEX: APDARES DĒĻI	2026-01	1.953	0.947	1.006	1.012	51.50	30.30	130.30	130.30
KARTEX: KARKASS	2026-01	0	0.255	0.255	0.065		17.50	84.20	130.30
KARTEX: KOKMATERIĀLI	2026-01	0	0.837	0.837	0.701		750.00	850.00	130.30
KARTEX: TERASES DĒĻI	2026-01	0	0.544	0.544	0.296		34.50	134.50	130.30
KARTEX: ŽOGA DĒĻI	2026-01	0	0	0	0		0.00	95.90	130.30
BUVNIKS: NEĒVELĒTI	2026-02	4.166	2.411	1.754	3.078	42.10	9.30	128.90	130.30
BUVNIKS: ĒVELĒTI	2026-02	0	0.878	0.878	0.77		90.50	184.40	130.30
KARTEX: APDARES DĒĻI	2026-02	0	1.953	1.953	3.813		58.80	130.30	130.30
KARTEX: KARKASS	2026-02	0.486	0	0.486	0.236	100.00	33.30	84.20	130.30
KARTEX: KOKMATERIĀLI	2026-02	0	0	0	0		0.00	850.00	130.30
KARTEX: TERASES DĒĻI	2026-02	0	0	0	0		0.00	134.50	130.30
KARTEX: ŽOGA DĒĻI	2026-02	0.054	0	0.054	0.003	100.00	4.10	95.90	130.30
BUVNIKS: NEĒVELĒTI	2026-03	12.333	4.166	8.167	66.708	66.20	43.20	128.90	130.30
BUVNIKS: ĒVELĒTI	2026-03	0.092	0	0.092	0.008	100.00	9.50	184.40	130.30
KARTEX: APDARES DĒĻI	2026-03	1.365	0	1.365	1.864	100.00	41.20	130.30	130.30
KARTEX: KARKASS	2026-03	0.975	0.486	0.489	0.239	50.10	33.50	84.20	130.30
KARTEX: KOKMATERIĀLI	2026-03	0.112	0	0.112	0.012	100.00	100.00	850.00	130.30
KARTEX: TERASES DĒĻI	2026-03	1.579	0	1.579	2.492	100.00	100.00	134.50	130.30
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.054	1.216	1.479	95.70	91.80	95.90	130.30

4. pielikums

Vienkāršas eksponenciālās izlīdzināšanas rezultāts

material_group	test_month	actual, m3	prediction, m3	abs_error, m3	sq_error, m3	ape, %	custom_ape, %	group_wape , %	wape, %
BUVNIKS: NEĒVELĒTI	2026-01	2.411	20.542	18.13	328.713	751.90	95.90	189.40	199.40
BUVNIKS: ĒVELĒTI	2026-01	0.878	1.725	0.848	0.718	96.60	87.40	388.10	199.40
KARTEX: APDARES DĒĻI	2026-01	1.953	3.154	1.202	1.444	61.50	36.20	163.60	199.40
KARTEX: KARKASS	2026-01	0	0.129	0.129	0.017		8.90	90.50	199.40
KARTEX: KOKMATERIĀLI	2026-01	0	1.637	1.637	2.678		1466.10	3722.20	199.40
KARTEX: TERASES DĒĻI	2026-01	0	1.625	1.625	2.639		102.90	213.90	199.40
KARTEX: ŽOGA DĒĻI	2026-01	0	0.102	0.102	0.01		7.70	99.80	199.40
BUVNIKS: NEĒVELĒTI	2026-02	4.166	17.952	13.786	190.053	330.90	72.90	189.40	199.40
BUVNIKS: ĒVELĒTI	2026-02	0	1.604	1.604	2.573		165.40	388.10	199.40
KARTEX: APDARES DĒĻI	2026-02	0	2.983	2.983	8.895		89.90	163.60	199.40
KARTEX: KARKASS	2026-02	0.486	0.111	0.375	0.141	77.20	25.70	90.50	199.40
KARTEX: KOKMATERIĀLI	2026-02	0	1.403	1.403	1.968		1256.60	3722.20	199.40
KARTEX: TERASES DĒĻI	2026-02	0	1.393	1.393	1.939		88.20	213.90	199.40
KARTEX: ŽOGA DĒĻI	2026-02	0.054	0.087	0.033	0.001	61.40	2.50	99.80	199.40
BUVNIKS: NEĒVELĒTI	2026-03	12.333	16.228	3.895	15.173	31.60	20.60	189.40	199.40
BUVNIKS: ĒVELĒTI	2026-03	0.092	1.403	1.311	1.72	1425.80	135.30	388.10	199.40
KARTEX: APDARES DĒĻI	2026-03	1.365	2.61	1.244	1.548	91.10	37.50	163.60	199.40
KARTEX: KARKASS	2026-03	0.975	0.158	0.817	0.667	83.80	55.90	90.50	199.40
KARTEX: KOKMATERIĀLI	2026-03	0.112	1.227	1.116	1.245	999.50	999.50	3722.20	199.40
KARTEX: TERASES DĒĻI	2026-03	1.579	1.218	0.36	0.13	22.80	22.80	213.90	199.40
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.083	1.187	1.409	93.50	89.70	99.80	199.40

5. pielikums

ARIMA rezultāts

material_group	test_month	actual, m3	prediction, m3	abs_erro r, m3	sq_error, m3	ape, %	order	custom _ape, %	group_w ape, %	wape, %
BUVNIKS: NEĒVELĒTI	2026-01	2.411	31.953	29.542	872.731	1225.20	(1, 1, 1)	156.20	235.50	225.30
BUVNIKS: ĒVELĒTI	2026-01	0.878	2.393	1.515	2.296	172.70	(0, 1, 2)	156.30	516.50	225.30
KARTEX: APDARES DĒĻI	2026-01	1.953	2.393	0.441	0.194	22.60	(0, 1, 2)	13.30	95.90	225.30
KARTEX: KARKASS	2026-01	0	0.032	0.032	0.001		(2, 1, 0)	2.20	99.30	225.30
KARTEX: KOKMATERIĀLI	2026-01	0	2.925	2.925	8.558		(0, 1, 2)	2620.60	4619.10	225.30
KARTEX: TERASES DĒĻI	2026-01	0	0	0	0		(2, 1, 0)	0.00	100.00	225.30
KARTEX: ŽOGA DĒĻI	2026-01	0	0.122	0.122	0.015		(0, 0, 0)	9.20	108.30	225.30
BUVNIKS: NEĒVELĒTI	2026-02	4.166	14.29	10.125	102.506	243.10	(0, 1, 2)	53.50	235.50	225.30
BUVNIKS: ĒVELĒTI	2026-02	0	1.98	1.98	3.919		(0, 1, 2)	204.20	516.50	225.30
KARTEX: APDARES DĒĻI	2026-02	0	2.587	2.587	6.694		(0, 1, 2)	78.00	95.90	225.30
KARTEX: KARKASS	2026-02	0.486	0.042	0.444	0.197	91.40	(2, 1, 0)	30.40	99.30	225.30
KARTEX: KOKMATERIĀLI	2026-02	0	1.67	1.67	2.788		(0, 1, 2)	1495.80	4619.10	225.30
KARTEX: TERASES DĒĻI	2026-02	0	0	0	0		(2, 1, 0)	0.00	100.00	225.30
KARTEX: ŽOGA DĒĻI	2026-02	0.054	0	0.054	0.003	100.00	(0, 1, 2)	4.10	108.30	225.30
BUVNIKS: NEĒVELĒTI	2026-03	12.333	7.46	4.873	23.745	39.50	(0, 1, 1)	25.80	235.50	225.30
BUVNIKS: ĒVELĒTI	2026-03	0.092	1.604	1.512	2.286	1643.80	(0, 1, 1)	156.00	516.50	225.30
KARTEX: APDARES DĒĻI	2026-03	1.365	1.521	0.156	0.024	11.40	(0, 1, 1)	4.70	95.90	225.30
KARTEX: KARKASS	2026-03	0.975	0	0.975	0.95	100.00	(1, 0, 0)	66.70	99.30	225.30
KARTEX: KOKMATERIĀLI	2026-03	0.112	0.673	0.561	0.315	502.70	(0, 1, 2)	502.70	4619.10	225.30
KARTEX: TERASES DĒĻI	2026-03	1.579	0	1.579	2.492	100.00	(2, 1, 0)	100.00	100.00	225.30
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.012	1.258	1.583	99.10	(1, 0, 1)	95.00	108.30	225.30

6. pielikums

LSTM rezultāts

material_group	test_month	actual, m3	prediction, m3	abs_error, m3	sq_error, m3	ape, %	custom_ape, %	group_wape , %	wape, %
BUVNIKS: NEĒVELĒTI	2026-01	2.411	8.032	5.621	31.598	233.10	29.70	110.70	254.90
BUVNIKS: ĒVELĒTI	2026-01	0.878	3.339	2.462	6.061	280.50	253.90	1581.80	254.90
KARTEX: APDARES DĒĻI	2026-01	1.953	8.044	6.092	37.108	312.00	183.60	522.20	254.90
KARTEX: KARKASS	2026-01	0	0.079	0.079	0.006		5.40	66.60	254.90
KARTEX: KOKMATERIĀLI	2026-01	0	1.873	1.873	3.506		1677.40	2108.00	254.90
KARTEX: TERASES DĒĻI	2026-01	0	6.249	6.249	39.05		395.90	777.20	254.90
KARTEX: ŽOGA DĒĻI	2026-01	0	0.051	0.051	0.003		3.90	101.80	254.90
BUVNIKS: NEĒVELĒTI	2026-02	4.166	1.18	2.985	8.912	71.70	15.80	110.70	254.90
BUVNIKS: ĒVELĒTI	2026-02	0	7.098	7.098	50.384		732.20	1581.80	254.90
KARTEX: APDARES DĒĻI	2026-02	0	8.135	8.135	66.174		245.20	522.20	254.90
KARTEX: KARKASS	2026-02	0.486	0.034	0.452	0.205	93.10	31.00	66.60	254.90
KARTEX: KOKMATERIĀLI	2026-02	0	0.369	0.369	0.136		330.60	2108.00	254.90
KARTEX: TERASES DĒĻI	2026-02	0	3.508	3.508	12.305		222.20	777.20	254.90
KARTEX: ŽOGA DĒĻI	2026-02	0.054	0.027	0.027	0.001	49.30	2.00	101.80	254.90
BUVNIKS: NEĒVELĒTI	2026-03	12.333	0	12.333	152.105	100.00	65.20	110.70	254.90
BUVNIKS: ĒVELĒTI	2026-03	0.092	5.867	5.775	33.354	6278.90	595.70	1581.80	254.90
KARTEX: APDARES DĒĻI	2026-03	1.365	4.465	3.1	9.608	227.00	93.40	522.20	254.90
KARTEX: KARKASS	2026-03	0.975	0.533	0.442	0.195	45.30	30.20	66.60	254.90
KARTEX: KOKMATERIĀLI	2026-03	0.112	0	0.112	0.012	100.00	100.00	2108.00	254.90
KARTEX: TERASES DĒĻI	2026-03	1.579	4.09	2.511	6.307	159.10	159.10	777.20	254.90
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0	1.27	1.613	100.00	95.90	101.80	254.90

7. pielikums

LSTM ar datu sintētiku rezultāts

material_group	test_month	actual, m3	prediction, m3	abs_error, m3	sq_error, m3	ape, %	custom_ape, %	group_wape , %	wape, %
BUVNIEKS: NEĒVELĒTI	2026-01	2.411	9.848	7.436	55.299	308.40	39.30	126.60	252.60
BUVNIEKS: ĒVELĒTI	2026-01	0.878	2.526	1.649	2.718	187.90	170.10	1289.90	252.60
KARTEX: APDARES DĒĻI	2026-01	1.953	6.313	4.361	19.016	223.30	131.40	641.30	252.60
KARTEX: KARKASS	2026-01	0	0.155	0.155	0.024		10.60	98.70	252.60
KARTEX: KOKMATERIĀLI	2026-01	0	0	0	0		0.00	1563.70	252.60
KARTEX: TERASES DĒĻI	2026-01	0	0.751	0.751	0.564		47.60	485.70	252.60
KARTEX: ŽOGA DĒĻI	2026-01	0	0.103	0.103	0.011		7.80	99.70	252.60
BUVNIEKS: NEĒVELĒTI	2026-02	4.166	0	4.166	17.352	100.00	22.00	126.60	252.60
BUVNIEKS: ĒVELĒTI	2026-02	0	2.848	2.848	8.11		293.70	1289.90	252.60
KARTEX: APDARES DĒĻI	2026-02	0	7.177	7.177	51.507		216.30	641.30	252.60
KARTEX: KARKASS	2026-02	0.486	0.117	0.369	0.136	75.90	25.30	98.70	252.60
KARTEX: KOKMATERIĀLI	2026-02	0	0	0	0		0.00	1563.70	252.60
KARTEX: TERASES DĒĻI	2026-02	0	3.775	3.775	14.252		239.20	485.70	252.60
KARTEX: ŽOGA DĒĻI	2026-02	0.054	0.114	0.06	0.004	111.80	4.60	99.70	252.60
BUVNIEKS: NEĒVELĒTI	2026-03	12.333	0	12.333	152.105	100.00	65.20	126.60	252.60
BUVNIEKS: ĒVELĒTI	2026-03	0.092	8.101	8.009	64.145	8707.40	826.10	1289.90	252.60
KARTEX: APDARES DĒĻI	2026-03	1.365	11.106	9.741	94.883	713.40	293.60	641.30	252.60
KARTEX: KARKASS	2026-03	0.975	0.057	0.918	0.842	94.20	62.80	98.70	252.60
KARTEX: KOKMATERIĀLI	2026-03	0.112	1.857	1.746	3.047	1563.70	1563.70	1563.70	252.60
KARTEX: TERASES DĒĻI	2026-03	1.579	4.72	3.142	9.87	199.00	199.00	485.70	252.60
KARTEX: ŽOGA DĒĻI	2026-03	1.27	0.113	1.157	1.339	91.10	87.40	99.70	252.60

Mākslīgā intelekta rīka izmantošanas piemērs

Help implement an LSTM model for monthly timber sales forecasting using Python/PyTorch

I'll sketch a practical PyTorch pipeline: prepare monthly/grouped sequences, standardize safely, build an LSTM with optional timber/material embeddings, train, validate, and inverse-transform forecasts.

Thought for 5s >

Below is a solid starting implementation for **monthly timber sales forecasting** with grouped/material-aware LSTM.

PyTorch `nn.LSTM` can use `batch_first=True`, meaning input shape is `(batch, timesteps, features)`, which fits time-series windows well. `DataLoader` is the standard way to batch/shuffle datasets during training.

[PyTorch Docu...](#)

[PyTorch Docu...](#)

Python



Run

```
import numpy as np
import pandas as pd
import torch
from torch import nn
from torch.utils.data import Dataset, DataLoader

# -----
# 1. Example expected data
# -----
# df columns:
# date, material_id, sale_m3, received_m3, price, stock_m3, ...
#
# One row per material per month.

TIMESTEPS = 3
TARGET_COL = "sale_m3"
GROUP_COL = "material_id"
DATE_COL = "date"

FEATURE_COLS = [
    "sale_m3",
    "received_m3",
    "price",
    "stock_m3",
]

df = df.copy()
df[DATE_COL] = pd.to_datetime(df[DATE_COL])
df = df.sort_values([GROUP_COL, DATE_COL])
```

Mākslīgā intelekta rīka izmantošanas piemērs

Analyze LSTM and augmented LSTM forecasting results and compare model errors by sales-volume groups

The split by sales-volume groups explains the augmented LSTM behavior much better than the aggregate metrics alone. The overall WAPE improvement was very small (254.9% → 252.6%), while RMSE and MAPE became worse. [Deniss Grabovskis 231RDB217](#) Because of that, the additional case-level analysis and sales-volume grouping were necessary.

Using the non-zero sales median of 1.270 m³ as the threshold, the forecasts were divided into:

- zero-sales cases,
- low-volume non-zero sales,
- high-volume non-zero sales. [Deniss Grabovskis 231RDB217](#)

The grouped comparison shows:

Group	LSTM	Augmented LSTM	Interpretation
Zero-sales cases	MAE 3.420	MAE 1.851	Clear improvement
Low-volume non-zero sales	WAPE 356.95%	WAPE 490.99%	Worse
High-volume non-zero sales	WAPE 135.23%	WAPE 168.82%	Worse

[Deniss Grabovskis 231RDB217](#)

This means the synthetic augmentation mainly helped the model reduce false-positive predictions in months where actual sales were zero. Since zero-sales cases contribute to the WAPE numerator through absolute error while contributing nothing to the denominator, reducing those errors slightly improved the global WAPE result.

However, the model did not improve its ability to forecast actual non-zero demand. In both low-volume and high-volume sales groups, the augmented model produced larger forecasting errors. Therefore, the augmentation did not improve the forecasting model itself in a general sense — it mostly regularized the model toward predicting smaller values in sparse-demand situations. [Deniss Grabovskis 231RDB217](#)

The result is consistent with the structure of the dataset discussed earlier in the thesis: the training set is short, contains many zero-sales months, and has weak seasonal structure. [Deniss Grabovskis 231RDB217](#) The augmentation method only increased the number of training windows by averaging neighboring samples, but it did not introduce new demand patterns or additional business information. [Deniss Grabovskis 231RDB217](#)

As a result, the synthetic data smoothed local fluctuations instead of helping the LSTM learn stronger

Mākslīgā intelekta rīka izmantošanas piemērs

Identify data augmentation practices for limited time-series forecasting data

When time-series datasets are small, augmentation helps improve generalization, robustness, and resistance to overfitting. The best augmentation method depends on whether the data are seasonal, noisy, multivariate, irregular, or event-driven.

Common Data Augmentation Practices for Time-Series Forecasting

1. Noise Injection

Add small random perturbations to observations while preserving the signal structure.

Example:

- Gaussian noise
- Jittering

Useful for:

- Sensor data
- Financial series
- IoT forecasting

Pros:

- Simple
- Improves robustness

Risks:

- Too much noise distorts temporal dynamics

2. Time Warping

Randomly stretch or compress portions of the timeline.

Useful for:

- Human activity recognition
- Physiological signals
- Weather sequences

Helps models become invariant to slight temporal shifts

